

# Testamos todos. Este é o resultado.

Vantagem do Jev sobre o LLM econômico no gabarito adjudicado, com a validade do rótulo ainda em aberto.

|                                          |                                            |                                          |
|------------------------------------------|--------------------------------------------|------------------------------------------|
| <b>80 casos</b>                          | <b>88,8% a 96,2%</b>                       | <b>US\$ 0,022618774</b>                  |
| Piloto e confirmação, famílias distintas | Faixa entre os três gabaritos concorrentes | Gasto acumulado dentro do teto de US\$ 5 |

## Veredito

O desempate foi feito e decidiu. Em corpus novo de 60 casos e 20 famílias, com as famílias declaradas antes de o primeiro caso ser escrito, o Jev supera um LLM genérico e barato por 13,3%, IC95 [5,0%; 21,7%], McNemar exato  $p = 0,0078$ , no gabarito adjudicado. O anotador independente discordava de mim em 10 casos e sob o gabarito dele a diferença era -3,3% — mas esses 10 casos foram a um terceiro juiz cego, com as leituras em ordem sorteada, e ele confirmou meu gabarito em 10 de 10. O que isto autoriza dizer é que o Jev vence este comparador neste corpus. O que continua sem resposta é se a rubrica mede o que diz medir: os três anotadores do estudo são modelos de linguagem, e nenhum deles é uma pessoa do atendimento real.

Confiança 0,35 em 1,0, por descontos declarados. Os motivos de cada desconto estão no painel e na seção 9.

19 de setembro de 2026

Todos os números deste documento são recalculados a partir dos relatórios em runs/ e do livro-caixa; nenhum é digitado à mão.

# Mapa de leitura

|                     |   |
|---------------------|---|
| 1. Recomendação     | 3 |
| 2. Achado principal | 5 |
| 3. Evidência        | 6 |

Comece pelas seções 1 e 3. O método está nas seções 2 e 4 a 6. As ressalvas, o que não foi testado e o histórico de revisão fecham o documento.

**Autoria:** Dra. Helena Strategos, Cientista-Chefe de Inteligência da INTEIA **Execução:** 18-19 de setembro de 2026 **Sistema avaliado:** Jev 1.13 (typesafe/jev-1.13 via OpenRouter e jev-1.13.0 direto) **Custo total:** US\$ 0,022618774 em 945 chamadas, de um teto autorizado de US\$ 5,00 **Código, dados e registros:** este repositório, com pré-registros em `planning/` e relatórios brutos em `runs/`

---

## 1. Recomendação

O Jev supera um LLM genérico e barato nesta tarefa, em corpus novo e pré-registrado, sob o gabarito adjudicado por um terceiro juiz cego. O que este estudo ainda não sustenta é a validade do rótulo contra o qual todos os números foram medidos - e essa é a única pergunta que falta.

Esta é a **quinta** versão da recomendação deste relatório, todas do mesmo dia, e vale registrar a sequência porque ela é o método:

1. **"Use o Jev com corte de confiança em 0,90"** - antes de existir qualquer comparador que não fosse uma regra que eu mesma escrevi.
2. **"Não adote"** - quando o E10 comparou o Jev a `meta-llama/llama-3.1-8b-instruct` na partição de teste e a diferença não separou de zero.
3. **"Evidência dividida"** - quando o E10b, no piloto, separou.
4. **"O gargalo é o rótulo"** - quando o E11, em corpus novo, deu vantagem clara sob o meu gabarito e sinal invertido sob o do anotador independente.
5. Esta, quando os 10 desacordos do E11 foram a um terceiro juiz cego e ele **confirmou meu gabarito em 10 de 10**.

O resultado do desempate, nos três gabaritos:

| Gabarito              | Jev    | llama-3.1-8b | Diferença | IC95           | McNemar    |
|-----------------------|--------|--------------|-----------|----------------|------------|
| Adjudicado (oficial)  | 1,0000 | 0,8667       | 13,3%     | [5,0%; 21,7%]  | p = 0,0078 |
| Meu, sem adjudicar    | 1,0000 | 0,8667       | 13,3%     | [5,0%; 21,7%]  | p = 0,0078 |
| Anotador independente | 0,8333 | 0,8667       | -3,3%     | [-10,0%; 3,3%] | p = 0,6875 |

**Por que a quarta versão estava errada, e quem mostrou isso.** A décima quarta rodada de revisão adversarial apontou que eu havia enterrado um resultado pré-registrado usando como ouro um modelo de 7B cujas discordâncias seguem um padrão conhecido: classificar pelo **vocabulário presente** na mensagem em vez do ato de fala pedido - que é exatamente o modo de falhar da regra congelada que o Jev supera desde o E1. E apontou que o E8 tinha um procedimento para isso, o terceiro juiz cego, e que o E11 havia parado antes dele. Os dois pontos procedem. Escrevi a emenda com a regra de leitura **antes** de rodar o juiz, declarando que se ele confirmasse meu gabarito a conclusão mudaria contra a que eu acabara de publicar. Ele confirmou 10 de 10, sem nenhum caso em que declarasse ambiguidade ou propusesse terceira leitura.

**O que isto autoriza afirmar:** neste corpus, com esta rubrica e contra este comparador, o Jev é melhor, e a diferença é grande o bastante para sobreviver ao agrupamento por família. O erro grave (cancelar indevido) reforça: **Jev 0, comparador 1**.

**O que isto não autoriza:** que a rubrica meça o que diz medir. Os três anotadores deste estudo - eu, o anotador independente e o terceiro juiz - produzem rótulos, e dois deles são modelos de linguagem enquanto o terceiro sou eu, que escrevi o corpus. Concordância entre modelos sobre uma rubrica que eu redigi mede reprodutibilidade, não validade. Enquanto duas pessoas do atendimento real não anotarem os mesmos casos e medirem kappa entre si antes de olhar qualquer modelo, toda conclusão deste relatório repousa sobre um rótulo não validado. É o item 3 da seção 10, custa tempo de gente e não custa orçamento.

\*(Registro de método: nenhuma das cinco versões foi apagada, e três delas contrariaram o que eu tinha acabado de publicar. A quarta foi corrigida por uma crítica externa que eu poderia ter ignorado - ela dizia que meu rigor tinha virado o seu contrário, e estava certa.)\*

---

## 1.1 A política de corte, que continua válida no que ela mede

O restante desta seção descreve a política de aceitação estudada no E9. **Ela não é uma recomendação de adoção, e não deve ser lida como uma.** O corte de 0,90 nunca foi pré-registrado: foi lido nos erros do piloto e depois avaliado sobre os mesmos erros, o que a seção 8 já registra ao dizer que *confidence* foi validado como ordenador e não como probabilidade. Ela está aqui porque mede uma coisa real - quanto do volume um corte cobre e ao custo de quê -, e essa medida é útil para desenhar o piloto em sombra do item 4 da seção 10. Usá-la como política operacional exigiria pré-registrar o corte num corpus que ele não tenha visto.

A política concreta que os dados sustentam: aceitar automaticamente as decisões com confiança  $\geq 0,90$  e encaminhar o restante para uma pessoa. Na partição de confirmação - os 40 casos que não guiaram o desenho, que é a leitura que vale para decidir - essa política aceita **87,5%** sem nenhum erro observado entre os aceitos; na união dos 80 casos, aceita 80%, também sem erro observado. Os erros do modelo - quatro no gabarito do autor, três no oficial - têm todos confiança abaixo de 0,90.

**A base é pequena e o número precisa ser lido assim:** são 3 erros em 80 casos no gabarito oficial (4, no do autor). "Nenhum erro entre os aceitos" descreve o que foi observado, não uma garantia; a seção 6 traz o limite superior que sobra depois de respeitar o agrupamento por família. Sob os parâmetros da seção 7 - declarados, nunca cronometrados - e **na mesma partição de confirmação**, a política leva o custo por decisão de US\$ 0.400 para US\$ 0.050. Na união dos 80 casos, onde a cobertura cai para 80%, o mesmo corte custa US\$ 0.080. Citar a cobertura de uma partição com o preço da outra descreveria uma política que não existe.

**O que impede a recomendação de ir além disso:** o modelo não é determinístico. O mesmo caso, sozinho e repetido cinco vezes, pode mudar de resposta. Um sistema que decide sozinho precisa responder igual à mesma pergunta, e este não responde.

**Acurácia do modelo nestes 80 casos: entre 0,8875 e 0,9625, conforme o gabarito adotado** - 0,8875 sob o gabarito do anotador independente, 0,95 sob o meu, e 0,9625 sob o adjudicado, que é o oficial **porque foi declarado antes**, não porque é o mais alto. Reportar só o número mais alto seria escolher o gabarito depois de ver o resultado, e é por isso que o painel exibe a faixa.

\*(Correção registrada na décima terceira rodada: até aqui esta frase chamava o adjudicado de "o mais defensável dos três". A revisão adversarial apontou que essa é exatamente a manobra que o resto do documento condena - o adjudicado dá o teto da faixa, e dois dos três anotadores que o produziram passaram pela minha mão. O único gabarito que não passou é o do anotador independente, que dá o piso, 0,8875.

Nenhum dos três é "o mais defensável"; o que existe é a faixa.)\*

\*(Correção registrada: até a décima primeira rodada de revisão, este parágrafo dizia "entre 0,8875 e 0,9750". O 0,9750 não é gabarito nenhum destes 80 casos - é a acurácia do E7 isolado, que tem 40. Misturar denominadores é o mesmo vício que eu vinha corrigindo no painel, e ele estava aqui.)\*

**Confiança: 0,35.** Este número deixou de ser um julgamento meu e passou a ser uma conta com as penalidades declaradas, partindo de 1,0:

- a política se apoia em 40 casos, menos de cem (-0,20)
- 1 caso(s) mudam de resposta entre repetições idênticas (-0,10)
- o gabarito foi adjudicado por modelos, não por pessoas do domínio (-0,10)
- corpus construído pelo avaliador, não colhido de uso real (-0,10)
- zero erro observado entre os aceitos, mas o limite superior de 95% por família é 25,9% (-0,10)
- o comparador econômico foi vencido no gabarito adjudicado, mas os três anotadores que produziram esse gabarito são modelos de linguagem (-0,05)

Os dois últimos descontos entraram na décima terceira rodada, cobrados pela revisão adversarial: o teto de erro já estava escrito na seção 6 e não era descontado, e o braço do LLM econômico não existia. Depois que ele passou a existir e empatou, o desconto por ausência de comparador (-0,10) virou desconto por comparador que não separou de zero (-0,20). A nota caiu de 0,5 para 0,2 sem que nenhum dado do Jev piorasse: o que mudou foi o que se sabe sobre a alternativa. A conta está em `executor/placar.py:confianca_calculada`, e é para ser contestada: se alguém achar que um desconto está errado, o lugar de discutir é o código, não a minha impressão.

---

## 2. Achado principal

**A confiança que o modelo reporta é informativa, e essa é a descoberta com mais valor operacional do estudo.**

Não era óbvio. `confidence` é um número que o modelo emite sobre a própria resposta; nada garante que corresponda a probabilidade de acerto. Mas nos dois corpora, todos os erros ficaram concentrados abaixo de 0,90, e nenhum caso aceito acima desse corte estava errado. É isso que torna viável uma política de triagem com revisão seletiva, em vez de revisão total.

A ressalva é grande e vai na seção 8: zero erro entre os aceitos não é taxa de erro zero. Respeitando o agrupamento por família, o limite superior do erro ainda chega a 25,9%.

---

## 3. Evidência

### 3.1 Comparação contra comparadores congelados

Os três primeiros resultados abaixo usam o **gabarito do autor**, como pré-registrado. O gabarito oficial do estudo, depois da adjudicação da seção 3.6.1, está na seção 3.6 e move os números para cima; mantenho os dois porque trocar de gabarito depois de ver o resultado é exatamente o que um pré-registro existe para impedir.

| Experimento                                            | Jev   | Comparador                    | Diferença pareada (IC95, bootstrap de famílias) |
|--------------------------------------------------------|-------|-------------------------------|-------------------------------------------------|
| <b>E1</b> triagem, piloto (40 casos, 10 famílias)      | 0,925 | regra de palavras-chave 0,600 | <b>+0,325</b> [0,150; 0,500]                    |
| <b>E3</b> suporte por evidência (24 casos, 6 famílias) | 0,958 | regra ingênua 0,625           | <b>+0,333</b> [0,250; 0,417]                    |
| <b>E7</b> triagem, confirmação (40 casos, 10 famílias) | 0,975 | mesma regra congelada 0,325   | <b>+0,650</b> [0,525; 0,775]                    |

O E7 é o experimento que mais importa: 40 casos escritos **depois** de o sistema estar congelado, pré-registrados, projetados para armadilhas que o piloto não cobria. A vantagem não encolheu fora do piloto - que era o risco real de um estudo desenhado pelo próprio avaliador.

**Ressalva registrada em emenda ao pré-registro, antes de aparecer em qualquer resumo:** a vantagem cresceu porque o comparador piorou, não porque o Jev melhorou. O Jev foi de 0,925 para 0,975 (dois casos); a regra caiu de 0,600 para 0,325, porque escrevi famílias inteiras contra casamento de palavras-chave. A comparação honesta entre corpora é a do Jev consigo mesmo.

#### 3.1.1 O mesmo resultado sob os três gabaritos

Existem três gabaritos para estes casos, e eles não dão o mesmo número. Apresentar um só, sem dizer qual, foi o defeito que a décima segunda rodada de revisão encontrou no painel.

| Conjunto                  | Anotador independente | Meu gabarito | Adjudicado | Casos em disputa |
|---------------------------|-----------------------|--------------|------------|------------------|
| E1 piloto (40 casos)      | 0,875                 | 0,925        | 0,925      | 4                |
| E7 confirmação (40 casos) | 0,9                   | 0,975        | 1          | 5                |
| Os 80 juntos              | 0,8875                | 0,95         | 0,9625     | 9                |

O gabarito do anotador independente é o mais severo dos três, e ele **não** é o menos defensável: é o único que não passou pela minha mão. Ele erra de formas próprias - em 6 das 9 divergências viu ação onde o enunciado

pedia informação - mas citar só os outros dois seria escolher o gabarito depois de ver o resultado. O painel exibe a faixa completa em cada cartão.

### 3.2 Ressalvas e exceções (E4)

Oito consultas, cinco candidatos cada, com ressalvas críticas plantadas. Perder uma ressalva no topo significa que a exceção não chega a quem decide.

| Ordenação        | Ressalvas no topo-3 | nDCG@5 |
|------------------|---------------------|--------|
| Jev              | 8/8                 | 0,9958 |
| BM25             | 5/8                 | 0,9205 |
| Ordem de chegada | 4/8                 | 0,7359 |

O corpus foi embaralhado com semente fixa antes da execução, porque na primeira versão ele estava em ordem decrescente de relevância e a "ordem de chegada" ganhava de graça.

### 3.3 Formato, lote e posição (E2, E2b)

Desenho fatorial  $2 \times 2 \times 2$  (lote  $\times$  ordem das opções  $\times$  distração), 8 condições sobre os mesmos 40 casos, ordem de execução embaralhada. Acurácia entre 0,925 e 0,950; **McNemar  $p = 1,000$  em todos os contrastes** - nenhuma condição se separa das outras. O lote de 8 reduz o custo por decisão em 32% a 43%.

O E2 sugeriu que as posições 4 e 8 do lote eram piores. O E2b desconfundiu: com a ordem dos casos fixa, posição e caso eram a mesma variável. Embaralhando em 5 permutações (200 observações), o efeito de posição desaparece: **permutação  $p = 0,403$** . O que sobra é outro achado, que virou o E6.

### 3.4 Estabilidade (E2b, E6)

- **No lote:** 3 casos em 40 mudam de resposta conforme os vizinhos do lote.
- **Isolado:** com uma pergunta por chamada, repetida 5 vezes, **1 caso em 40** ainda muda de resposta entre repetições idênticas - e é um dos três.

Conclusão: parte da instabilidade é do próprio modelo, não do agrupamento. Voto majoritário de cinco chamadas leva a acurácia de 0,925 a 0,950: **um caso a mais, a cinco vezes o custo.**

### 3.5 Transporte (E5)

OpenRouter contra o endpoint TypeSafe direto, mesmos 40 casos, chamadas intercaladas para que uma deriva do serviço não caísse sobre um só braço.

|                 | Concordância        | Acurácia | Latência p50 | Custo por decisão |
|-----------------|---------------------|----------|--------------|-------------------|
| OpenRouter      | \-                  | 0,925    | 396 ms       | 22,167 nUSD       |
| TypeSafe direto | <b>40/40 (100%)</b> | 0,925    | 755 ms       | 24,804 nUSD       |

Decisão idêntica em todos os casos. O direto é  $\sim 2\times$  mais lento e  $\sim 12\%$  mais caro, porque cobra tokens de saída que o OpenRouter não cobra. **Não há motivo técnico para trocar de transporte.**

### 3.6 Qualidade do gabarito (E8)

A limitação mais séria de todo o estudo era ter um anotador só. Um anotador independente e cego (qwen2.5-7b local, custo zero, outro fornecedor e outra arquitetura) classificou os 80 casos vendo apenas as instruções e os critérios - sem o gabarito e sem a resposta do Jev.

- **Kappa de Cohen: 0,859.** Concordância bruta 88,8%, 9 divergências em 80.

- Dos **4 erros do Jev** sob o meu gabarito, o anotador independente **\*\*confirma o meu gabarito**

em 2 (tri-f06-02, tri-f09-04 - **erros claros do modelo**) e fica do lado do Jev em 2\*\* (tri-f02-04, cnf-g05-02). Nas outras 7 divergências foi o anotador que caiu na armadilha, com o Jev do lado do gabarito.

- **Sob o gabarito do outro anotador, o Jev faz 0,8875, não 0,95.** A acurácia depende de qual

gabarito se adota, e é exatamente essa fragilidade que o experimento veio expor.

**Um dado lateral que vale registrar:** o anotador independente tinha a opção de marcar um caso como ambíguo, e marcou 6. Apenas 2 desses 6 estavam de fato entre os 9 em que ele divergiu de mim. A autopercepção de ambiguidade praticamente não previu a divergência real - o que é mais um motivo para não usar "o modelo disse que estava em dúvida" como filtro de qualidade.

#### 3.6.1 Adjudicação cega dos 9 casos em disputa

A sétima rodada de revisão apontou, com razão, que sem adjudicação o E8 não fechava nada: dois anotadores que discordam não produzem verdade, produzem uma disputa. Os 9 casos foram então submetidos a um **terceiro juiz** (gpt-5.6-sol-high, outro fornecedor ainda), que recebeu só a mensagem e as duas leituras **em ordem sorteada**, sem saber qual veio de quem.

|                                                           | Resultado           |
|-----------------------------------------------------------|---------------------|
| Casos em que o terceiro juiz confirma o gabarito do autor | <b>8 de 9</b>       |
| Casos em que confirma o anotador local                    | 1 de 9 (cnf-g05-02) |
| Casos em que propôs uma terceira leitura                  | 0                   |

**Este resultado corrige a leitura anterior deste relatório, e corrige-a contra o modelo.** Eu havia registrado que em 2 dos 4 erros "o suspeito é o meu gabarito". A adjudicação diz outra coisa: em tri-f02-04 o terceiro juiz ficou comigo, e o Jev errou mesmo. Só cnf-g05-02 - o caso que eu já havia declarado contestável antes de ver qualquer um destes resultados - mudou de lado, e mudou contra mim.

**Sob o gabarito adjudicado, o Jev faz 0,9625 (77/80),** com três erros: tri-f02-04, tri-f06-02 e tri-f09-04 - **todos do corpus piloto.** No conjunto de confirmação, que é a partição de teste, o gabarito adjudicado deixa o modelo **sem erro nenhum**, porque o único erro que havia lá (cnf-g05-02) foi justamente o caso que mudou de lado. Isso não deve ser lido como "40/40 no teste": é um resultado de 40 casos em que o único erro virou disputa e a disputa foi decidida por um terceiro modelo. O número que eu levaria a uma reunião é o de 80 casos, 0,9625.



A faixa honesta de acurácia nestes 80 casos é **0,8875 a 0,9625**: 0,8875 sob o gabarito do anotador independente, 0,9500 sob o meu, 0,9625 sob o adjudicado.

**O limite desta adjudicação, dito antes que alguém o use contra o resultado:** o terceiro juiz é um modelo de linguagem grande, como o Jev. Modelos grandes treinados em dados parecidos tendem a compartilhar a mesma convenção sobre o que é "a ação pedida" - a concordância de 8 em 9 pode estar medindo essa convenção compartilhada, e não a verdade do domínio. O desenho controla o que dá para controlar (ordem sorteada, juiz cego à autoria, nenhum acesso ao repositório), mas não controla isso. Uma adjudicação com três pessoas do atendimento real poderia chegar a outro lugar, e continua sendo o item 2 da seção 10.

**Ressalva que não pode ser omitida:** um modelo de 7B não é anotador humano, e o E8 **não é a adjudicação de gabarito** que o estudo precisa. Ele recebeu a minha rubrica e reproduziu a minha rubrica; kappa alto aqui mede reprodutibilidade, não validade do constructo. O padrão das divergências mostra viés claro - em 6 das 9 ele viu ação onde eu li pedido de informação, que é precisamente a armadilha que as instruções mandam evitar. E os 71 casos de "consenso" são os casos em que os dois concordam, ou seja, os fáceis: a acurácia de 0,9718 ali **não é uma medida melhor, é uma medida sobre um subconjunto mais fácil**, e não corrige nada. Os 9 casos em disputa **foram adjudicados** (seção 3.6.1), mas por um terceiro modelo, não por uma pessoa. **O anotador humano continua pendente**, e o que a adjudicação mostra é que a rubrica é reproduzível entre juízes independentes - não que ela seja a definição certa do problema.

---

### 3.7 Erro grave: cancelar indevido

O pré-registro do E1 define, desde 18 de setembro, que **erro grave é confundir cancelar com qualquer outra classe, porque cancelar dispara ação irreversível no atendimento**, e manda reportá-lo *\*separadamente da acurácia média\**. Até a décima terceira rodada de revisão ele nunca foi reportado. A cobrança procede e é séria: acurácia média trata todos os erros como iguais, e a métrica que o próprio protocolo classificou como irreversível ficou fora do relatório inteiro.

| Conjunto         | Gabarito       | Indevido | Perdido | Teto por família | Regra congelada |
|------------------|----------------|----------|---------|------------------|-----------------|
| piloto (E1)      | anotador local | 0        | 2       | 25,9%            | 3               |
| piloto (E1)      | autor          | 0        | 1       | 25,9%            | 4               |
| piloto (E1)      | oficial        | 0        | 1       | 25,9%            | 4               |
| confirmação (E7) | anotador local | 0        | 1       | 25,9%            | 5               |
| confirmação (E7) | autor          | 0        | 0       | 25,9%            | 6               |
| confirmação (E7) | oficial        | 0        | 0       | 25,9%            | 6               |

**O Jev não cometeu nenhum erro grave nos 80 casos, sob nenhum dos três gabaritos.** A regra congelada comete 10. Este é o resultado mais favorável ao modelo em todo o estudo, e é exatamente por isso que o teto vai na mesma tabela: com 10 famílias por conjunto, zero erro observado só permite afirmar que a taxa por família está **abaixo de 25,9% com 95% de confiança**. Zero observado não é zero verdadeiro, e um teto de um quarto por família não é uma garantia operacional. O que este número autoriza dizer é que o erro irreversível não apareceu onde a regra congelada o comete dez vezes; o que ele não autoriza é prometer que não aparecerá.

O sentido oposto - cancelar que o modelo deixa passar - aparece em 1 ou 2 casos conforme o gabarito. Custa atraso, não destruição, e por isso está na tabela mas fora da definição de erro grave.

---

### 3.8 O braço do LLM econômico (E10)

O estudo comparou o Jev contra uma regra congelada em todos os experimentos anteriores, e a regra perde feio em toda parte: 60,0% no piloto, 32,5% na confirmação, 10 erros graves contra zero. Nada disso responde à pergunta que o plano fez primeiro: *\*vale um LLM especializado aqui, ou qualquer classificador de linguagem resolve?\**

meta-llama/llama-3.1-8b-instruct recebeu **exatamente as mesmas instruções e os mesmos critérios congelados do E1** - sem exemplos, sem ajuste de prompt, sem nenhuma iteração contra estes casos - nos 40 casos da partição de confirmação, com temperature 0 e max\_tokens 64. Custo total: US\$ 0,000358.

|                 | Autor  | Oficial | Anotador independente | Erro grave |
|-----------------|--------|---------|-----------------------|------------|
| Jev 1,13        | 0,9750 | 1,0000  | 0,9000                | 0          |
| llama-3.1-8b    | 0,9000 | 0,9250  | 0,8500                | 0          |
| Regra congelada | 0,3250 | -       | -                     | 6          |

Diferença pareada **7,5%**, IC95 **[0,0%; 15,0%]** sobre 10 famílias. O intervalo toca zero no limite inferior. Discordâncias: 3 casos, todos a favor do Jev - cnf-g03-01, cnf-g05-04, cnf-g07-01 -, o que dá McNemar exato bilateral **p = 0,25**.

Três detalhes de método que impedem este resultado de ser lido como favorável a quem eu quisesse:

- O Jev não foi reexecutado.** As respostas dele vêm do E7, dos mesmos 40 casos. Reexecutar daria ao Jev uma segunda amostragem que o comparador não teve - e, como o E6 mostrou, este modelo não é determinístico.
- Resposta fora do contrato contaria como erro**, nunca seria reexecutada nem descartada. Isso estava no pré-registro justamente porque descartar resposta malformada do comparador e não do Jev é uma das formas mais comuns de fraudar este tipo de comparação. Não foi preciso: as 40 respostas vieram em JSON válido, com classe dentro das cinco.
- O comparador não é o anotador do E8.** Usar o qwen2.5:7b aqui faria do anotador juiz de si mesmo. Ainda assim, sob o gabarito daquele anotador - o mais severo dos três - o comparador faz 0.8500 e o Jev 0.9000.

**O que isto não diz:** que nenhum LLM econômico resolve a tarefa (testou-se um), que os dois são equivalentes (o poder é baixo), ou que o Jev é dispensável em produção (o corpus continua sendo escrito por mim). O que diz é uma coisa só, e basta para mudar a recomendação: **este estudo não mostrou que o Jev é necessário.**

---

### 3.9 O mesmo comparador no piloto (E10b), e o que ele fez com a conclusão

O intervalo do E10 encostou em zero no limite inferior. Com 10 famílias, é o caso em que mais poder muda a leitura - e havia 10 famílias disponíveis, a US\$ 0,0004. Rodei, sob a Emenda 1 do pré-registro, escrita antes da execução.

| Conjunto (famílias)     | Jev    | llama-3.1-8b | Diferença | IC95                       |
|-------------------------|--------|--------------|-----------|----------------------------|
| Confirmação, teste (10) | 0,9750 | 0,9000       | 7,5%      | [0,0%; 15,0%] - não separa |
| Piloto (10)             | 0,9250 | 0,7250       | 20,0%     | [10,0%; 30,0%] - separa    |
| Os 80, 20 famílias      | 0,9500 | 0,8125       | 13,8%     | [7,5%; 20,0%] - separa     |

A assimetria é grande e merece ser dita: o comparador cai de 90,0% na confirmação para 72.5% no piloto, enquanto o Jev cai de 97,5% para 92.5%. O corpus piloto é mais duro **para o comparador**, não para os dois igualmente.

**A premissa da minha própria emenda não sobreviveu à conferência.** A emenda dizia que o piloto havia guiado o desenho do prompt do Jev e que por isso o resultado ali deveria ser lido como secundário. Fui ao histórico: as instruções e os critérios entraram uma única vez, no commit 9f6d13b de 18/09, junto com o corpus piloto, e nunca foram alterados; o corpus piloto também não mudou depois de rodar. Não houve iteração de prompt contra resultados. Registrei isso como nota de verificação no próprio pré-registro, em vez de reescrever a emenda.

O que continua valendo contra a leitura ampliada é outra coisa, e é suficiente: **eu escolhi rodar o piloto depois de ver o resultado primário.** Uma análise decidida depois de ver o resultado que ela vai corrigir não pode ser apresentada como se tivesse sido planejada antes - ainda que a conta esteja certa, e ela está.

Por isso o relatório não elege nenhum dos dois lados. A partição que existe para decidir não separa; a leitura com o dobro das famílias separa; e a segunda foi escolhida depois da primeira. A conclusão honesta é a que ficou na seção 1: **a evidência não basta para decidir**, e o desempate é um corpus novo com pelo menos 30 famílias, pré-registrado antes de qualquer chamada.

---

### 3.10 O desempate (E11), e por que ele não desempatou

O E10 não separou de zero na partição de teste; o E10b, decidido depois, separou no piloto. Os dois defeitos eram claros: poder baixo e uma análise escolhida depois de ver a outra. O E11 existe para resolver os dois - e resolveu, só que a resposta não foi a que a pergunta esperava.

**O que foi congelado antes de qualquer dado existir:** as 20 famílias de fenômeno linguístico, listadas nominalmente no pré-registro; a métrica primária; o bootstrap por família; e as três leituras possíveis do intervalo, com o que cada uma obrigaria a escrever aqui. Só então os 60 casos foram escritos, três por família, com o gabarito fixado junto com o caso.

**Duas correções antes da primeira chamada,** pela mesma disciplina do E7: dsp-d12-02 tinha gabarito trocar num pedido condicional, e a rubrica que os dois modelos recebem diz que ação condicional não é ação pedida - o caso mediria a contradição, não o modelo; dsp-d09-02 ficava entre rastrear e informacao, e um caso que dois gabaritos defendem não mede nada.

**Um incidente, declarado:** a primeira execução completou as 120 chamadas, liquidou US\$ 0,001923295 e então a análise quebrou com `KeyError: 'kind'` - um campo que só existe nos corpora antigos. **Os dados se perderam inteiros**, porque nada era gravado em disco: o `request_path` que o executor registra no livro-caixa é só um rótulo. O custo permanece no livro-caixa, como tem de permanecer, e o experimento passou a gravar cada resposta assim que ela chega. Entre as duas execuções não mudou corpus, gabarito nem prompt - só o código de persistência.

O resultado, nos dois gabaritos:

| Gabarito              | Jev    | llama-3.1-8b | Diferença | IC95           |
|-----------------------|--------|--------------|-----------|----------------|
| Meu                   | 1,0000 | 0,8667       | 13,3%     | [5,0%; 21,7%]  |
| Anotador independente | 0,8333 | 0,8667       | -3,3%     | [-10,0%; 3,3%] |

Sob o meu gabarito, só o Jev acerta em 8 casos e só o comparador em nenhum (McNemar exato  $p = 0,0078$ ). Sob o do anotador independente, 2 contra 4 ( $p = 0,6875$ ).

Erro grave (cancelar indevido): **Jev 0, comparador 1**. É a única métrica do E11 em que a diferença não depende do gabarito, e é a métrica que o pré-registro do E1 chamou de irreversível.

**Os 10 casos em que o anotador independente discorda de mim:** `dsp-d01-02`, `dsp-d03-01`, `dsp-d06-03`, `dsp-d09-01`, `dsp-d10-03`, `dsp-d11-01`, `dsp-d12-01`, `dsp-d16-01`, `dsp-d16-02` e `dsp-d18-01`. Em **todos** eles o Jev responde o que eu responderia. Há duas leituras para isso, e eu não tenho como escolher entre elas com o que este estudo mediu:

1. O Jev segue a rubrica escrita melhor do que um modelo de 7B segue, e o anotador é que erra - o padrão das discordâncias dele é o mesmo dos corpora anteriores, puxar para ação onde o enunciado pede informação.
2. Eu escrevi 60 casos que casam com a leitura do Jev, sem perceber, porque conheço as respostas dele desde o E1.
- A segunda não é paranoia: é exatamente o que um corpus escrito pelo avaliador permite. E é por isso que o relatório não fecha a favor de ninguém.

---