

O que fazer com o Jev.

Onde ele se destaca, quanto se ganha, onde é preciso ter cuidado e o que ainda falta para decidir adoção.

87,8% a 98,3%

Acurácia nos 230 casos, entre os três gabaritos

82,2%

Resolvidas sem pessoa no corte de 0,99, sem erro observado

US\$ 0,035707114

Custo de toda a avaliação, de um teto de US\$ 5

Em uma frase

O Jev funciona e supera com folga o método simples que se usa hoje; o que ainda não está provado é que ele seja necessário diante de um LLM genérico e barato — e essa dúvida não se resolve com mais medição, e sim com dado real e anotação humana.

Documento de decisão. O método, as contra-hipóteses e o histórico de revisão estão no relatório final, em docs/RELATORIO-FINAL-JEV.md.

19 de setembro de 2026

Todos os números são recalculados dos relatórios em runs/ e do livro-caixa; nenhum é digitado à mão.

Mapa de leitura

1. Para que serve, em uma frase	3
2. As três aplicações testadas, com o ganho medido	3
3. Onde ele brilha: o tipo de texto que derruba os outros métodos	3
4. Como aplicar, passo a passo	4
5. O cuidado mais importante: a confiança é útil, mas não é garantia	4
6. Quanto custa e quanto economiza	5
7. Os cuidados, em ordem de risco	5
8. Os 15 sistemas do ecossistema: por onde começar	6
9. Placar final: todos os testes, o resultado e a consequência	6
10. O que decidir hoje	8

As seções 1 a 4 dizem para que serve e como aplicar, com exemplos reais. A 5 e a 7 trazem os cuidados; a 6, os custos. A seção 8 trata dos 15 sistemas do ecossistema e a 9 traz o placar de todos os experimentos, com a consequência prática de cada um.

Documento de aplicação. Todos os números vêm dos experimentos E1 a E12 e do livro-caixa; nenhum é estimativa. O método completo está em docs/RELATORIO-FINAL-JEV.md.

1. Para que serve, em uma frase

O Jev lê um texto e responde **uma pergunta fechada sobre ele**, devolvendo a resposta já classificada, com um número de confiança junto. Ele não escreve, não resume e não conversa: ele decide entre opções que você define.

É isso que ele faz bem, e é aí que ele deve ser aplicado: **onde existe uma decisão repetitiva, com opções conhecidas, que hoje alguém toma lendo texto.**

2. As três aplicações testadas, com o ganho medido

Aplicação 1 - Triagem: "o que esta pessoa está pedindo?"

Entra uma mensagem, sai uma classe: cancelar, rastrear, trocar, cobrança, informacao (as classes são suas, estas foram as do teste).

Acerto: 92,5% no piloto, 97,5% no conjunto de confirmação, 98,9% no corpus novo. O método por palavra-chave, no mesmo teste: 60,0%, 32,5%. Não é uma melhora incremental - é outra categoria de resultado.

Onde aplicar: fila de atendimento, caixa de entrada de e-mail, WhatsApp comercial, protocolo de demandas internas. Qualquer lugar onde alguém hoje lê para encaminhar.

Aplicação 2 - Verificação: "o que este texto afirma se sustenta no documento?"

Entra uma afirmação mais a evidência, sai se a evidência suporta a afirmação.

Acerto: 95,8%, contra 62,5% da regra simples.

Onde aplicar: conferência de citação antes de protocolar peça, checagem de número em relatório contra a fonte, revisão de contrato contra o que a proposta prometia. É a aplicação mais diretamente útil no trabalho jurídico.

Aplicação 3 - Ordenação: "qual trecho muda a resposta?"

Entra uma pergunta mais um conjunto de trechos, sai a ordem de relevância.

Achou as 8 de 8 ressalvas e colocou no top-3. O BM25, que é o método de busca padrão, achou 5 de 8. A ordem original do documento, 4 de 8.

Onde aplicar: achar a exceção escondida no meio do contrato, a cláusula que inverte a regra geral, o parágrafo que ressalva o artigo anterior. **É onde ele mais se destaca sobre o que se usa hoje**, e é a aplicação menos óbvia das três.

3. Onde ele brilha: o tipo de texto que derruba os outros métodos

O ganho do Jev não aparece em mensagem fácil - aparece exatamente onde o vocabulário engana. Estes são casos reais do teste, em que o Jev acertou e um LLM genérico e barato errou:

"Como faço para cancelar pelo aplicativo? Não quero que vocês cancelem nada agora, só quero saber o caminho." - a palavra "cancelar" aparece duas vezes e o pedido é de informação. Jev: *informação*. LLM barato: *cancelar*.

"Minha esposa quer cancelar o plano. Eu não quero; só me explica o que muda." - a ação é de terceiro e foi recusada por quem escreve. Jev: *informação*. LLM barato: *cancelar*.

"Quero devolver o produto e receber o dinheiro de volta. Não quero outro no lugar." - "devolver" cabe em duas classes, e quem decide é o complemento. Jev: *cobrança*. LLM barato: *trocar*.

"Meu irmão disse para deixar como está, mas quem paga a conta sou eu: cancela." - o pedido real vem depois de uma opinião contrária. Jev: *cancelar*. LLM barato: *cobrança*.

"Do pedido 8891, cancela só o item da caneca. O resto mantém." - cancelamento parcial continua sendo cancelamento. Jev: *cancelar*. LLM barato: *trocar*.

O padrão é sempre o mesmo: **a ação está negada, citada, condicional, adiada ou parcial**. É o texto que uma pessoa apressada também erra. Se o seu material tem muito disso - e texto de cliente e texto jurídico têm -, é aí que o investimento se paga.

4. Como aplicar, passo a passo

Passo 1 - Escreva as opções antes de qualquer teste. De 3 a 6 classes, cada uma com uma frase dizendo o que entra nela. As classes ruins são as que se sobrepõem; se você hesita entre duas ao classificar à mão, o modelo também vai hesitar - e o problema é da definição, não dele.

Passo 2 - Separe a classe perigosa. Em toda aplicação existe uma opção cujo erro não tem volta (aqui foi cancelar). Essa classe **nunca** vai para o automático, qualquer que seja a confiança. Trate-a como fila prioritária de revisão humana.

Passo 3 - Rode em sombra por duas semanas. O modelo responde, ninguém age pela resposta dele, e no fim se compara com o que a equipe decidiu. É barato: mil decisões custam **US\$ 0,02**.

Passo 4 - Escolha o corte pelo seu dado, não pelo deste estudo. Veja a seção 5: o corte que funcionou em dois corpora falhou no terceiro. O corte tem de ser calibrado no material real.

Passo 5 - Só então automatize o que passa do corte, mantendo revisão humana do resto e da classe perigosa. E volte a medir de tempos em tempos: o modelo não é determinístico.

5. O cuidado mais importante: a confiança é útil, mas não é garantia

Este é o ponto que mais muda a aplicação prática, e ele vem do experimento mais recente.

Nos dois primeiros corpora, **todos** os erros do Jev ficaram abaixo de 0,90 de confiança. Aceitar automaticamente o que passava de 0,90 resolvia 87,5% das mensagens **sem nenhum erro entre as aceitas**. Era a política recomendada.

No corpus novo, com 90 casos, isso não se repetiu: o único erro do modelo veio com **confiança 0,98**. Ele disse "cobrança" onde a resposta era "informação", na mensagem **"Posso pedir a segunda via por aqui? Antes de pedir, me confirma se ela vem com o mesmo vencimento."** - o pedido estava adiado, e ele leu como já feito.

Corte de confiança	Resolve sozinho	Erros entre os aceitos
0,90	95,6%	1
0,95	90,0%	1
0,99	82,2%	0

O que isso significa na prática: a confiança continua sendo informativa - 82% das mensagens passam de 0,99 e nenhuma delas estava errada. Mas ela **não é uma garantia**, e um corte calibrado num conjunto não se transporta para outro. Aplique com corte alto (0,99), revisão da classe perigosa, e recalibre no seu próprio material antes de subir o volume.

6. Quanto custa e quanto economiza

Item	Valor medido
Mil decisões do Jev	US\$ 0,022
Mil decisões do LLM genérico mais barato testado	US\$ 0,006
Revisar tudo com gente (2 min a US\$ 12/h, parâmetro declarado, não cronometrado)	US\$ 0,40 por decisão
Com corte de confiança e revisão só do resto	US\$ 0,05 por decisão
Toda a avaliação, 1.474 chamadas reais	US\$ 0,0357

A conta que decide **não é a do modelo** - é a do tempo de pessoa. O custo por decisão do Jev é de dois centésimos de centavo; o da revisão humana é vinte mil vezes maior. Por isso o passo 3 acima inclui cronometrar a revisão: se ela leva 30 segundos e não 2 minutos, a economia real é um quarto da que está nesta tabela, e ninguém mediu isso ainda.

7. Os cuidados, em ordem de risco

1. Não automatize a classe irreversível. Em 230 casos o Jev não errou nenhum cancelar - e ainda assim a estatística só garante que a taxa por família de casos está abaixo de 9,5%. Um em cada dez é muito quando o erro cancela o contrato de um cliente.

2. Recalibre o corte no seu material. Seção 5. Foi o achado que mudou esta recomendação.

3. A mesma pergunta pode ter resposta diferente. Repetindo 40 casos cinco vezes, 1 caso mudou de resposta. Para decisão que não tem volta: pergunte três vezes e vá pela maioria, ou mande para revisão.

4. O teste foi feito com casos construídos, não com material real. Nenhuma das 230 mensagens veio de um canal de produção. Elas medem discriminação de linguagem, não a bagunça do mundo real - e essa é a razão do passo 3 da seção 4.

5. A vantagem sobre um LLM genérico e barato não está provada. Contra o método simples de hoje, a vantagem é enorme e sólida. Contra quatro LLMs baratos, ela existe sob o critério de correção desta casa e desaparece sob o critério de um anotador independente. Se o seu caso de uso tolera 88% a 91% de acerto, um modelo genérico barato pode bastar - e custa um quarto.

6. A acurácia depende da mistura de assuntos. Nas quatro distribuições simuladas, a acurácia esperada vai de 95,0% a 97,2%. Um canal dominado por rastreio não se comporta como um dominado por cobrança.

8. Os 15 sistemas do ecossistema: por onde começar

O plano previa avaliar 15 repositórios que usam o Jev. O que foi executado mede **o estado do código de cada um** - a suíte de testes deles - e não o comportamento com o modelo.

Estado	Sistemas
Suíte passa (5)	Jev Search, Jev Ultrafast, jevcal, Jev Rerank Bench, Every
Suíte falha (7)	Jev CLI, Janus, pi-warden, System One Adapter, HEIST//ONE, SemIf/OpenJev, pi-model-router
Não rodou (3)	Jev Review, should-ai-kill-us-all, Jeeves

Leitura prática: comece pelos cinco que passam - neles o esforço vai para a aplicação, não para consertar o repositório. O System One Adapter é o mais caro da lista (108 falhas e 64 erros). Passar na própria suíte não diz que o componente é bom; diz que ele está inteiro.

9. Placar final: todos os testes, o resultado e a consequência

Doze experimentos, 1.474 chamadas reais, US\$ 0,0357. Esta é a lista inteira - o que cada um perguntou, o que respondeu e o que isso muda na hora de aplicar.

#	O que foi testado	Resultado	Consequência prática
E1	Triagem, corpus piloto: Jev contra regra por palavra-chave	92,5% contra 60,0%	O método simples de hoje não é páreo. Aplicar vale a pena.
E2	O formato do pedido muda a resposta? (lote, ordem, texto irrelevante junto)	92,5% a 95,0% nas 8 condições, sem diferença significativa	Pode mandar de 8 em 8 para baratear, e ruído no texto não atrapalha.
E2b	O lugar da mensagem no lote influencia?	Efeito de posição some ao embaralhar ($p = 0,40$); 3 de 40 casos mudam conforme os vizinhos	Lote é seguro na média, mas um caso limítrofe pode virar. Não use lote para a classe perigosa.
E3	Uma afirmação se sustenta na evidência anexada?	95,8% contra 62,5%	Aplicação recomendada: conferência de citação e de número contra a fonte.

#	O que foi testado	Resultado	Consequência prática
E4	Achar o trecho que muda a resposta	8 de 8 ressalvas no top-3; BM25 acha 5	Aplicação recomendada: achar a exceção escondida em contrato ou norma.
E5	O resultado muda conforme o caminho de acesso?	40 de 40 casos iguais nos dois; o acesso direto é 2× mais lento e mais caro	Use o caminho mais barato. Trocar de fornecedor de acesso não muda a resposta.
E6	Perguntando 5 vezes a mesma coisa, responde igual?	1 caso de 40 oscila; votar em 3 chamadas estabiliza	Para decisão sem volta, pergunte 3 vezes e vá pela maioria.
E7	Triagem em conjunto separado, que nunca guiou nada	97,5% contra 32,5%	O resultado do E1 não foi sorte nem ajuste ao teste.
E8	Um anotador independente concorda com o nosso critério?	Concordância 87,4%, kappa 0,84; 29 divergências em 230 casos	O critério de correção é reprodutível, mas não é unânime - e as divergências são casos reais de ambiguidade.
E9	E se a mistura de assuntos do canal for outra?	Acurácia esperada entre 95,0% e 97,2%	Estime pelo seu canal: mais rastreio ou mais cobrança muda o número.
E10 / E10b	Um LLM genérico e barato faz o mesmo?	Empata no conjunto de teste; o Jev ganha no piloto	Primeira vez que a necessidade do Jev ficou em dúvida.
E11	Desempate: corpus novo, 20 famílias	Jev ganha sob o nosso critério; empata sob o do anotador independente	A dúvida não era de amostra pequena.
E12	Replicação: 30 famílias novas, 4 LLMs baratos	Jev 98,9% , os outros de 84,4% a 91,1% sob o nosso critério; sem vantagem sob o critério independente	Triplicar o teste não resolveu: o que decide é quem escreve o gabarito.
-	Erro grave (cancelar indevido), todos os corpora	0 em 230 casos , sob os três critérios; a regra simples comete 10 em 80	O erro que dói não apareceu - mas a estatística só garante abaixo de 9,5% por família.
-	A confiança avisa quando ele erra?	Funcionou em 2 corpora; falhou no 3º (erro com confiança 0,98)	Use corte 0,99 e recalibre no seu material. É o cuidado nº 2.

As três consequências que resumem tudo:

- 1. Aplicar vale a pena onde o método atual é regra simples ou busca por palavra.** O ganho é grande, replicado três vezes e sobrevive a mudança de formato, de ordem e de fornecedor de acesso.
- 2. O que não se provou é que precise ser o Jev.** Contra LLMs genéricos baratos, a vantagem depende de quem escreveu o gabarito - e eles custam um quarto do preço.
- 3. Nada disso autoriza automatizar sem rede.** A confiança falha, o modelo oscila, e a classe irreversível continua exigindo gente.

10. O que decidir hoje

Pergunta	Resposta
Onde aplicar primeiro?	Verificação de afirmação contra evidência, e ordenação para achar ressalva. São as duas em que a vantagem sobre o método atual é maior e o risco é menor.
E a triagem de atendimento?	Vale, mas com corte alto e revisão da classe perigosa - e ela é a aplicação em que o LLM barato mais se aproxima.
Dá para automatizar?	Só acima de 0,99 de confiança, nunca na classe irreversível, e depois de recalibrar no seu material.
Quanto custa experimentar?	Praticamente nada: mil decisões por dois centavos. O custo do piloto é o tempo de quem compara os resultados.
Qual o maior risco?	Automatizar sobre um critério de correção que ninguém de fora validou.
O que destrava tudo?	200 mensagens reais e duas pessoas anotando os mesmos casos. Não é dinheiro - sobram US\$ 4,96 do teto. É acesso a dado real e tempo de gente.

Cada número deste documento sai dos arquivos em `runs/`, do livro-caixa em `runs/ledger.sqlite3` e do painel em `1ab/`. O relatório final traz o experimento de origem de cada afirmação.

- Helena.