

Testamos todos. Este é o resultado.

Com mais famílias e quatro comparadores, a vantagem do Jev continua dependendo de quem escreveu o gabarito.

80 casos	88,8% a 96,2%	US\$ 0,035707114
Piloto e confirmação, famílias distintas	Faixa entre os três gabaritos concorrentes	Gasto acumulado dentro do teto de US\$ 5

Veredito

A replicação foi feita e não mudou a natureza do problema, só o tamanho da amostra. Em corpus novo de 90 casos e 30 famílias, declaradas antes de o primeiro caso ser escrito, contra ****quatro**** comparadores econômicos de quatro fornecedores, o Jev acerta 98,9% e supera todos eles no gabarito adjudicado, por 7,8% a 14,4%, com todos os IC95 acima de zero. Os 10 casos em que eu e o anotador independente discordamos foram a um terceiro juiz cego, de outro fornecedor, que confirmou meu gabarito em 10 de 10. ****Sob o gabarito do anotador independente, que é o único que não passou pela minha mão, a mesma comparação vai de 0,0% a 8,9%, e o intervalo contém zero contra mais de um comparador.**** Era essa a divergência que o E11 tinha encontrado com 20 famílias e um comparador só, e que este experimento existia para resolver com mais poder. Ela não era falta de amostra: triplicar as famílias e quadruplicar os comparadores não a moveu. O que decide o resultado não é quanto se mede, é quem escreveu o rótulo — e os três anotadores deste estudo continuam sendo modelos de linguagem.

Confiança 0,25 em 1,0, por descontos declarados. Os motivos de cada desconto estão no painel e na seção 9.

19 de setembro de 2026

Todos os números deste documento são recalculados a partir dos relatórios em runs/ e do livro-caixa; nenhum é digitado à mão.

Mapa de leitura

1. Recomendação	4
2. Achado principal	7
3. Evidência	7
4. Mecanismo: por que funciona	16
5. Contra-hipóteses testadas	17
6. Calibração	17
7. Custo e operação	18
8. Limites - o que este estudo não autoriza afirmar	19
9. Controle financeiro e integridade do processo	20
10. Próximo movimento	24

Comece pelas seções 1 e 3. O método está nas seções 2 e 4 a 6. As ressalvas, o que não foi testado e o histórico de revisão fecham o documento.

Autoria: Dra. Helena Strategos, Cientista-Chefe de Inteligência da INTEIA **Execução:** 18-19 de setembro de 2026 **Sistema avaliado:** Jev 1.13 (typesafe/jev-1.13 via OpenRouter e jev-1.13.0 direto) **Custo total:** US\$ 0,035707114 em 1.474 chamadas, de um teto autorizado de US\$ 5,00, conciliado contra um extrato de provedor de US\$ 0,034640289 **Código, dados e registros:** este repositório, com pré-registros em `planning/` e relatórios brutos em `runs/`

1. Recomendação

O Jev supera quatro LLMs genéricos e baratos nesta tarefa, em corpus novo e pré-registrado, sob o gabarito adjudicado por um terceiro juiz cego - e não supera nenhum deles de forma estatisticamente distinguível sob o gabarito do único anotador que não passou pela minha mão. A replicação com o triplo de famílias e o quádruplo de comparadores não moveu essa divergência, e é isso que este estudo tem de mais sólido a dizer: o gargalo não é a amostra, é o rótulo.

Esta é a **sexta** versão da recomendação deste relatório, e vale registrar a sequência porque ela é o método:

1. **"Use o Jev com corte de confiança em 0,90"** - antes de existir qualquer comparador que não fosse uma regra que eu mesma escrevi.
2. **"Não adote"** - quando o E10 comparou o Jev a `meta-llama/llama-3.1-8b-instruct` na partição de teste e a diferença não separou de zero.
3. **"Evidência dividida"** - quando o E10b, no piloto, separou.
4. **"O gargalo é o rótulo"** - quando o E11, em corpus novo, deu vantagem clara sob o meu gabarito e sinal invertido sob o do anotador independente.
5. **"Vantagem do Jev no gabarito adjudicado"** - quando os 10 desacordos do E11 foram a um terceiro juiz cego e ele **confirmou meu gabarito em 10 de 10**.
6. Esta, quando o E12 replicou tudo com 30 famílias novas e **quatro** comparadores de quatro fornecedores, o segundo juiz cego confirmou meu gabarito em outros 10 de 10, e a divergência entre os gabaritos **continuou exatamente onde estava**.

O resultado da replicação (E12), nos três gabaritos, contra os quatro comparadores:

Gabarito	Jev	llama-3.1-8b	mistral-nemo	gemma-3-12b	gpt-oss-20b	Leitura
Adjudicado (oficial)	0,9889	0,8778	0,9111	0,8444	0,8444	vantagem em todos
Meu, sem adjudicar	0,9889	0,8778	0,9111	0,8444	0,8444	vantagem em todos
Anotador independente	0,9000	0,9000	0,8556	0,8222	0,7111	sem evidência

As diferenças pareadas, no gabarito oficial, vão de +7,8% (IC95 [3,3%; 13,3%], contra o `mistral-nemo`) a +14,4% (IC95 [7,8%; 21,1%] e [6,7%; 22,2%], contra o `gemma` e o `gpt-oss`). Sob o gabarito do anotador independente, a

diferença contra o llama-3.1-8b é **exatamente zero** (IC95 [-6,7%; 6,7%], McNemar p = 1,0000) e o intervalo contém zero também contra o mistral-nemo e o gemma. A regra de leitura estava congelada antes de existir um único caso: só há vantagem se o intervalo separar de zero contra **todos**, e a conclusão só é reportada como vantagem se sobreviver aos três gabaritos. Ela não sobreviveu, e o veredito pré-registrado é depende-do-gabarito.

O resultado do desempate anterior (E11), que o E12 replica:

Gabarito	Jev	llama-3.1-8b	Diferença	IC95	McNemar
Adjudicado (oficial)	1,0000	0,8667	13,3%	[5,0%; 21,7%]	p = 0,0078
Meu, sem adjudicar	1,0000	0,8667	13,3%	[5,0%; 21,7%]	p = 0,0078
Anotador independente	0,8333	0,8667	-3,3%	[-10,0%; 3,3%]	p = 0,6875

Por que a quarta versão estava errada, e quem mostrou isso. A décima quarta rodada de revisão adversarial apontou que eu havia enterrado um resultado pré-registrado usando como ouro um modelo de 7B cujas discordâncias seguem um padrão conhecido: classificar pelo **vocabulário presente** na mensagem em vez do ato de fala pedido - que é exatamente o modo de falhar da regra congelada que o Jev supera desde o E1. E apontou que o E8 tinha um procedimento para isso, o terceiro juiz cego, e que o E11 havia parado antes dele. Os dois pontos procedem. Escrevi a emenda com a regra de leitura **antes** de rodar o juiz, declarando que se ele confirmasse meu gabarito a conclusão mudaria contra a que eu acabara de publicar. Ele confirmou 10 de 10, sem nenhum caso em que declarasse ambiguidade ou propusesse terceira leitura.

O que isto autoriza afirmar: neste corpus, com esta rubrica e contra este comparador, o Jev é melhor, e a diferença é grande o bastante para sobreviver ao agrupamento por família. No erro grave (cancelar indevido) **o Jev não cometeu nenhum sob nenhum dos três gabaritos**; o comparador cometeu um sob dois deles e nenhum sob o terceiro - o detalhe está na seção 3.10, e ele é menos favorável do que a versão anterior desta frase dizia.

O que isto não autoriza: que a rubrica meça o que diz medir. Os três anotadores deste estudo - eu, o anotador independente e o terceiro juiz - produzem rótulos, e dois deles são modelos de linguagem enquanto o terceiro sou eu, que escrevi o corpus. Concordância entre modelos sobre uma rubrica que eu redigi mede reprodutibilidade, não validade. Enquanto duas pessoas do atendimento real não anotarem os mesmos casos e medirem kappa entre si antes de olhar qualquer modelo, toda conclusão deste relatório repousa sobre um rótulo não validado. É o item 3 da seção 10, custa tempo de gente e não custa orçamento.

(Registro de método: nenhuma das cinco versões foi apagada, e três delas contrariaram o que eu tinha acabado de publicar. A quarta foi corrigida por uma crítica externa que eu poderia ter ignorado - ela dizia que meu rigor tinha virado o seu contrário, e estava certa.)

1.1 A política de corte, que continua válida no que ela mede

O restante desta seção descreve a política de aceitação estudada no E9. **Ela não é uma recomendação de adoção, e não deve ser lida como uma.** O corte de 0,90 nunca foi pré-registrado: foi lido nos erros do piloto e depois avaliado sobre os mesmos erros, o que a seção 8 já registra ao dizer que *confidence* foi validado como ordenador e não como probabilidade. Ela está aqui porque mede uma coisa real - quanto do volume um corte cobre e ao custo de quê -, e essa medida é útil para desenhar o piloto em sombra do item 4 da seção 10. Usá-la como política operacional exigiria pré-registrar o corte num corpus que ele não tenha visto.

A política concreta que os dados sustentam: aceitar automaticamente as decisões com confiança $\geq 0,90$ e encaminhar o restante para uma pessoa. Na partição de confirmação - os 40 casos que não guiaram o desenho, que é a leitura que vale para decidir - essa política aceita **87,5%** sem nenhum erro observado entre os aceitos; na união dos 80 casos, aceita 80%, também sem erro observado. Os erros do modelo - quatro no gabarito do autor, três no oficial - têm todos confiança abaixo de 0,90.

A base é pequena e o número precisa ser lido assim: são 3 erros em 80 casos no gabarito oficial (4, no do autor). "Nenhum erro entre os aceitos" descreve o que foi observado, não uma garantia; a seção 6 traz o limite superior que sobra depois de respeitar o agrupamento por família. Sob os parâmetros da seção 7 - declarados, nunca cronometrados - e **na mesma partição de confirmação**, a política leva o custo por decisão de US\$ 0.400 para US\$ 0.050. Na união dos 80 casos, onde a cobertura cai para 80%, o mesmo corte custa US\$ 0.080. Citar a cobertura de uma partição com o preço da outra descreveria uma política que não existe.

O que impede a recomendação de ir além disso: o modelo não é determinístico. O mesmo caso, sozinho e repetido cinco vezes, pode mudar de resposta. Um sistema que decide sozinho precisa responder igual à mesma pergunta, e este não responde.

Acurácia do modelo nestes 80 casos: entre 0,8875 e 0,9625, conforme o gabarito adotado - 0,8875 sob o gabarito do anotador independente, 0,95 sob o meu, e 0,9625 sob o adjudicado, que é o oficial **porque foi declarado antes**, não porque é o mais alto. Reportar só o número mais alto seria escolher o gabarito depois de ver o resultado, e é por isso que o painel exibe a faixa.

(Correção registrada na décima terceira rodada: até aqui esta frase chamava o adjudicado de "o mais defensável dos três". A revisão adversarial apontou que essa é exatamente a manobra que o resto do documento condena - o adjudicado dá o teto da faixa, e dois dos três anotadores que o produziram passaram pela minha mão. O único gabarito que não passou é o do anotador independente, que dá o piso, 0,8875. Nenhum dos três é "o mais defensável"; o que existe é a faixa.)

(Correção registrada: até a décima primeira rodada de revisão, este parágrafo dizia "entre 0,8875 e 0,9750". O 0,9750 não é gabarito nenhum destes 80 casos - é a acurácia do E7 isolado, que tem 40. Misturar denominadores é o mesmo vício que eu vinha corrigindo no painel, e ele estava aqui.)

Confiança: 0,35. Este número deixou de ser um julgamento meu e passou a ser uma conta com as penalidades declaradas, partindo de 1,0:

- a política se apoia em 40 casos, menos de cem (-0,20)
- 1 caso(s) mudam de resposta entre repetições idênticas (-0,10)
- o gabarito foi adjudicado por modelos, não por pessoas do domínio (-0,10)
- corpus construído pelo avaliador, não colhido de uso real (-0,10)
- zero erro observado entre os aceitos, mas o limite superior de 95% por família é 25,9% (-0,10)

- o comparador econômico foi vencido no gabarito adjudicado, mas os três anotadores que produziram esse gabarito são modelos de linguagem (-0,05)

Os dois últimos descontos entraram na décima terceira rodada, cobrados pela revisão adversarial: o teto de erro já estava escrito na seção 6 e não era descontado, e o braço do LLM econômico não existia. Depois que ele passou a existir e empatou, o desconto por ausência de comparador (-0,10) virou desconto por comparador que não separou de zero (-0,20). A nota caiu de 0,5 para 0,2 sem que nenhum dado do Jev piorasse: o que mudou foi o que se sabe sobre a alternativa. A conta está em `executor/placar.py:confianca_calculada`, e é para ser contestada: se alguém achar que um desconto está errado, o lugar de discutir é o código, não a minha impressão.

2. Achado principal

A confiança que o modelo reporta é informativa, e essa é a descoberta com mais valor operacional do estudo.

Não era óbvio. `confidence` é um número que o modelo emite sobre a própria resposta; nada garante que corresponda a probabilidade de acerto. Mas nos dois corpora, todos os erros ficaram concentrados abaixo de 0,90, e nenhum caso aceito acima desse corte estava errado. É isso que torna viável uma política de triagem com revisão seletiva, em vez de revisão total.

A ressalva é grande e vai na seção 8: zero erro entre os aceitos não é taxa de erro zero. Respeitando o agrupamento por família, o limite superior do erro ainda chega a 25,9%.

3. Evidência

3.1 Comparação contra comparadores congelados

Os três primeiros resultados abaixo usam o **gabarito do autor**, como pré-registrado. O gabarito oficial do estudo, depois da adjudicação da seção 3.6.1, está na seção 3.6 e move os números para cima; mantenho os dois porque trocar de gabarito depois de ver o resultado é exatamente o que um pré-registro existe para impedir.

Experimento	Jev	Comparador	Diferença pareada (IC95, bootstrap de famílias)
E1 triagem, piloto (40 casos, 10 famílias)	0,925	regra de palavras-chave 0,600	+0,325 [0,150; 0,500]
E3 suporte por evidência (24 casos, 6 famílias)	0,958	regra ingênua 0,625	+0,333 [0,250; 0,417]

Experimento	Jev	Comparador	Diferença pareada (IC95, bootstrap de famílias)
E7 triagem, confirmação (40 casos, 10 famílias)	0,975	mesma regra congelada 0,325	+0,650 [0,525; 0,775]

O E7 é o experimento que mais importa: 40 casos escritos **depois** de o sistema estar congelado, pré-registrados, projetados para armadilhas que o piloto não cobria. A vantagem não encolheu fora do piloto - que era o risco real de um estudo desenhado pelo próprio avaliador.

Ressalva registrada em emenda ao pré-registro, antes de aparecer em qualquer resumo: a vantagem cresceu porque o comparador piorou, não porque o Jev melhorou. O Jev foi de 0,925 para 0,975 (dois casos); a regra caiu de 0,600 para 0,325, porque escrevi famílias inteiras contra casamento de palavras-chave. A comparação honesta entre corpora é a do Jev consigo mesmo.

3.1.1 O mesmo resultado sob os três gabaritos

Existem três gabaritos para estes casos, e eles não dão o mesmo número. Apresentar um só, sem dizer qual, foi o defeito que a décima segunda rodada de revisão encontrou no painel.

Conjunto	Anotador independente	Meu gabarito	Adjudicado	Casos em disputa
E1 piloto (40 casos)	0,875	0,925	0,925	4
E7 confirmação (40 casos)	0,9	0,975	1	5
Os 80 juntos	0,8875	0,95	0,9625	9

O gabarito do anotador independente é o mais severo dos três, e ele **não** é o menos defensável: é o único que não passou pela minha mão. Ele erra de formas próprias - em 6 das 9 divergências viu ação onde o enunciado pedia informação - mas citar só os outros dois seria escolher o gabarito depois de ver o resultado. O painel exibe a faixa completa em cada cartão.

3.2 Ressalvas e exceções (E4)

Oito consultas, cinco candidatos cada, com ressalvas críticas plantadas. Perder uma ressalva no topo significa que a exceção não chega a quem decide.

Ordenação	Ressalvas no topo-3	nDCG@5
Jev	8/8	0,9958
BM25	5/8	0,9205
Ordem de chegada	4/8	0,7359

O corpus foi embaralhado com semente fixa antes da execução, porque na primeira versão ele estava em ordem decrescente de relevância e a "ordem de chegada" ganhava de graça.

3.3 Formato, lote e posição (E2, E2b)

Desenho fatorial $2 \times 2 \times 2$ (lote $\times$ ordem das opções $\times$ distração), 8 condições sobre os mesmos 40 casos, ordem de execução embaralhada. Acurácia entre 0,925 e 0,950; **McNemar $p = 1,000$ em todos os contrastes** - nenhuma condição se separa das outras. O lote de 8 reduz o custo por decisão em 32% a 43%.

O E2 sugeriu que as posições 4 e 8 do lote eram piores. O E2b desconfundiu: com a ordem dos casos fixa, posição e caso eram a mesma variável. Embaralhando em 5 permutações (200 observações), o efeito de posição desaparece: **permutação $p = 0,403$** . O que sobra é outro achado, que virou o E6.

3.4 Estabilidade (E2b, E6)

- **No lote:** 3 casos em 40 mudam de resposta conforme os vizinhos do lote.
- **Isolado:** com uma pergunta por chamada, repetida 5 vezes, **1 caso em 40** ainda muda de resposta entre repetições idênticas - e é um dos três.

Conclusão: parte da instabilidade é do próprio modelo, não do agrupamento. Voto majoritário de cinco chamadas leva a acurácia de 0,925 a 0,950: **um caso a mais, a cinco vezes o custo**.

3.5 Transporte (E5)

OpenRouter contra o endpoint TypeSafe direto, mesmos 40 casos, chamadas intercaladas para que uma deriva do serviço não caísse sobre um só braço.

	Concordância	Acurácia	Latência p50	Custo por decisão
OpenRouter	\-	0,925	396 ms	22,167 nUSD
TypeSafe direto	40/40 (100%)	0,925	755 ms	24,804 nUSD

Decisão idêntica em todos os casos. O direto é $\sim 2\times$ mais lento e $\sim 12\%$ mais caro, porque cobra tokens de saída que o OpenRouter não cobra. **Não há motivo técnico para trocar de transporte.**

3.6 Qualidade do gabarito (E8)

A limitação mais séria de todo o estudo era ter um anotador só. Um anotador independente e cego (qwen2.5-7b local, custo zero, outro fornecedor e outra arquitetura) classificou os 80 casos vendo apenas as instruções e os critérios - sem o gabarito e sem a resposta do Jev.

- **Kappa de Cohen: 0,859.** Concordância bruta 88,8%, 9 divergências em 80.
- Dos **4 erros do Jev** sob o meu gabarito, o anotador independente ****confirma o meu gabarito** em 2 (**tri-f06-02, tri-f09-04 - erros claros do modelo**) e fica do lado do Jev em 2** (**tri-f02-04, cnf-g05-02**). Nas outras 7 divergências foi o anotador que caiu na armadilha, com o Jev do lado do gabarito.
- **Sob o gabarito do outro anotador, o Jev faz 0,8875, não 0,95.** A acurácia depende de qual gabarito se adota, e é exatamente essa fragilidade que o experimento veio expor.

Um dado lateral que vale registrar: o anotador independente tinha a opção de marcar um caso como ambíguo, e marcou 6. Apenas 2 desses 6 estavam de fato entre os 9 em que ele divergiu de mim. A autopercepção de ambiguidade praticamente não previu a divergência real - o que é mais um motivo para não usar "o modelo disse que estava em dúvida" como filtro de qualidade.

3.6.1 Adjudicação cega dos 9 casos em disputa

A sétima rodada de revisão apontou, com razão, que sem adjudicação o E8 não fechava nada: dois anotadores que discordam não produzem verdade, produzem uma disputa. Os 9 casos foram então submetidos a um **terceiro juiz** (gpt-5.6-sol-high, outro fornecedor ainda), que recebeu só a mensagem e as duas leituras **em ordem sorteada**, sem saber qual veio de quem.

	Resultado
Casos em que o terceiro juiz confirma o gabarito do autor	8 de 9
Casos em que confirma o anotador local	1 de 9 (cnf-g05-02)
Casos em que propôs uma terceira leitura	0

Este resultado corrige a leitura anterior deste relatório, e corrige-a contra o modelo. Eu havia registrado que em 2 dos 4 erros "o suspeito é o meu gabarito". A adjudicação diz outra coisa: em tri-f02-04 o terceiro juiz ficou comigo, e o Jev errou mesmo. Só cnf-g05-02 - o caso que eu já havia declarado contestável antes de ver qualquer um destes resultados - mudou de lado, e mudou contra mim.

Sob o gabarito adjudicado, o Jev faz 0,9625 (77/80), com três erros: tri-f02-04, tri-f06-02 e tri-f09-04 - **todos do corpus piloto**. No conjunto de confirmação, que é a partição de teste, o gabarito adjudicado deixa o modelo **sem erro nenhum**, porque o único erro que havia lá (cnf-g05-02) foi justamente o caso que mudou de lado. Isso não deve ser lido como "40/40 no teste": é um resultado de 40 casos em que o único erro virou disputa e a disputa foi decidida por um terceiro modelo. O número que eu levaria a uma reunião é o de 80 casos, 0,9625.

A faixa honesta de acurácia nestes 80 casos é **0,8875 a 0,9625**: 0,8875 sob o gabarito do anotador independente, 0,9500 sob o meu, 0,9625 sob o adjudicado.

O limite desta adjudicação, dito antes que alguém o use contra o resultado: o terceiro juiz é um modelo de linguagem grande, como o Jev. Modelos grandes treinados em dados parecidos tendem a compartilhar a mesma convenção sobre o que é "a ação pedida" - a concordância de 8 em 9 pode estar medindo essa convenção compartilhada, e não a verdade do domínio. O desenho controla o que dá para controlar (ordem sorteada, juiz cego à autoria, nenhum acesso ao repositório), mas não controla isso. Uma adjudicação com três pessoas do atendimento real poderia chegar a outro lugar, e continua sendo o item 2 da seção 10.

Ressalva que não pode ser omitida: um modelo de 7B não é anotador humano, e o E8 **não é a adjudicação de gabarito** que o estudo precisa. Ele recebeu a minha rubrica e reproduziu a minha rubrica; kappa alto aqui mede reprodutibilidade, não validade do constructo. O padrão das divergências mostra viés claro - em 6 das 9 ele viu ação onde eu li pedido de informação, que é precisamente a armadilha que as instruções mandam evitar. E os 71 casos de "consenso" são os casos em que os dois concordam, ou seja, os fáceis: a acurácia de 0,9718 ali **não é uma medida melhor, é uma medida sobre um subconjunto mais fácil**, e não corrige nada. Os 9 casos em disputa **foram adjudicados** (seção 3.6.1), mas por um terceiro modelo, não por uma pessoa. **O anotador humano continua pendente**, e o que a adjudicação mostra é que a rubrica é reproduzível entre

juízes independentes - não que ela seja a definição certa do problema.

3.7 Erro grave: cancelar indevido

O pré-registro do E1 define, desde 18 de setembro, que **erro grave é confundir cancelar com qualquer outra classe, porque cancelar dispara ação irreversível no atendimento**, e manda reportá-lo **separadamente da acurácia média**. Até a décima terceira rodada de revisão ele nunca foi reportado. A cobrança procede e é séria: acurácia média trata todos os erros como iguais, e a métrica que o próprio protocolo classificou como irreversível ficou fora do relatório inteiro.

Conjunto	Gabarito	Indevido	Perdido	Teto por família	Regra congelada
piloto (E1)	anotador local	0	2	25,9%	3
piloto (E1)	autor	0	1	25,9%	4
piloto (E1)	oficial	0	1	25,9%	4
confirmação (E7)	anotador local	0	1	25,9%	5
confirmação (E7)	autor	0	0	25,9%	6
confirmação (E7)	oficial	0	0	25,9%	6

O Jev não cometeu nenhum erro grave nos 80 casos, sob nenhum dos três gabaritos. A regra congelada comete 10. Este é o resultado mais favorável ao modelo em todo o estudo, e é exatamente por isso que o teto vai na mesma tabela: com 10 famílias por conjunto, zero erro observado só permite afirmar que a taxa por família está **abaixo de 25,9% com 95% de confiança**. Zero observado não é zero verdadeiro, e um teto de um quarto por família não é uma garantia operacional. O que este número autoriza dizer é que o erro irreversível não apareceu onde a regra congelada o comete dez vezes; o que ele não autoriza é prometer que não aparecerá.

O sentido oposto - cancelar que o modelo deixa passar - aparece em 1 ou 2 casos conforme o gabarito. Custa atraso, não destruição, e por isso está na tabela mas fora da definição de erro grave.

3.8 O braço do LLM econômico (E10)

O estudo comparou o Jev contra uma regra congelada em todos os experimentos anteriores, e a regra perde feio em toda parte: 60,0% no piloto, 32,5% na confirmação, 10 erros graves contra zero. Nada disso responde à pergunta que o plano fez primeiro: **vale um LLM especializado aqui, ou qualquer classificador de linguagem resolve?**

meta-llama/llama-3.1-8b-instruct recebeu **exatamente as mesmas instruções e os mesmos critérios congelados do E1** - sem exemplos, sem ajuste de prompt, sem nenhuma iteração contra estes casos - nos 40 casos da partição de confirmação, com temperature 0 e max_tokens 64. Custo total: US\$ 0,000358.

	Autor	Oficial	Anotador independente	Erro grave
Jev 1,13	0,9750	1,0000	0,9000	0
llama-3.1-8b	0,9000	0,9250	0,8500	0
Regra congelada	0,3250	-	-	6

Diferença pareada **7,5%**, IC95 **[0,0%; 15,0%]** sobre 10 famílias. O intervalo toca zero no limite inferior. Discordâncias: 3 casos, todos a favor do Jev - cnf-g03-01, cnf-g05-04, cnf-g07-01 -, o que dá McNemar exato bilateral **p = 0,25**.

Três detalhes de método que impedem este resultado de ser lido como favorável a quem eu quisesse:

- O Jev não foi reexecutado.** As respostas dele vêm do E7, dos mesmos 40 casos. Reexecutar daria ao Jev uma segunda amostragem que o comparador não teve - e, como o E6 mostrou, este modelo não é determinístico.
 - Resposta fora do contrato contaria como erro**, nunca seria reexecutada nem descartada. Isso estava no pré-registro justamente porque descartar resposta malformada do comparador e não do Jev é uma das formas mais comuns de fraudar este tipo de comparação. Não foi preciso: as 40 respostas vieram em JSON válido, com classe dentro das cinco.
 - O comparador não é o anotador do E8.** Usar o qwen2.5:7b aqui faria do anotador juiz de si mesmo. Ainda assim, sob o gabarito daquele anotador - o mais severo dos três - o comparador faz 0.8500 e o Jev 0.9000.
- O que isto não diz:** que nenhum LLM econômico resolve a tarefa (testou-se um), que os dois são equivalentes (o poder é baixo), ou que o Jev é dispensável em produção (o corpus continua sendo escrito por mim). O que diz é uma coisa só, e basta para mudar a recomendação: **este estudo não mostrou que o Jev é necessário**.

3.9 O mesmo comparador no piloto (E10b), e o que ele fez com a conclusão

O intervalo do E10 encostou em zero no limite inferior. Com 10 famílias, é o caso em que mais poder muda a leitura - e havia 10 famílias disponíveis, a US\$ 0,0004. Rodei, sob a Emenda 1 do pré-registro, escrita antes da execução.

Conjunto (famílias)	Jev	llama-3.1-8b	Diferença	IC95
Confirmação, teste (10)	0,9750	0,9000	7,5%	[0,0%; 15,0%] - não separa
Piloto (10)	0,9250	0,7250	20,0%	[10,0%; 30,0%] - separa
Os 80, 20 famílias	0,9500	0,8125	13,8%	[7,5%; 20,0%] - separa

A assimetria é grande e merece ser dita: o comparador cai de 90,0% na confirmação para 72.5% no piloto, enquanto o Jev cai de 97,5% para 92.5%. O corpus piloto é mais duro **para o comparador**, não para os dois

igualmente.

A premissa da minha própria emenda não sobreviveu à conferência. A emenda dizia que o piloto havia guiado o desenho do prompt do Jev e que por isso o resultado ali deveria ser lido como secundário. Fui ao histórico: as instruções e os critérios entraram uma única vez, no commit 9f6d13b de 18/09, junto com o corpus piloto, e nunca foram alterados; o corpus piloto também não mudou depois de rodar. Não houve iteração de prompt contra resultados. Registrei isso como nota de verificação no próprio pré-registro, em vez de reescrever a emenda.

O que continua valendo contra a leitura ampliada é outra coisa, e é suficiente: **eu escolhi rodar o piloto depois de ver o resultado primário.** Uma análise decidida depois de ver o resultado que ela vai corrigir não pode ser apresentada como se tivesse sido planejada antes - ainda que a conta esteja certa, e ela está.

Por isso o relatório não elege nenhum dos dois lados. A partição que existe para decidir não separa; a leitura com o dobro das famílias separa; e a segunda foi escolhida depois da primeira. Esta era a conclusão antes da adjudicação dos 10 desacordos. A seção 3.11 conta o que aconteceu com ela.

3.10 O desempate (E11): o que ele mediu, e o que quase me fez concluir errado

O E10 não separou de zero na partição de teste; o E10b, decidido depois, separou no piloto. Os dois defeitos eram claros: poder baixo e uma análise escolhida depois de ver a outra. O E11 existe para resolver os dois - e resolveu, só que a resposta não foi a que a pergunta esperava.

O que foi congelado antes de qualquer dado existir: as 20 famílias de fenômeno linguístico, listadas nominalmente no pré-registro; a métrica primária; o bootstrap por família; e as três leituras possíveis do intervalo, com o que cada uma obrigaria a escrever aqui. Só então os 60 casos foram escritos, três por família, com o gabarito fixado junto com o caso.

Duas correções antes da primeira chamada, pela mesma disciplina do E7: dsp-d12-02 tinha gabarito trocar num pedido condicional, e a rubrica que os dois modelos recebem diz que ação condicional não é ação pedida - o caso mediria a contradição, não o modelo; dsp-d09-02 ficava entre rastrear e informacao, e um caso que dois gabaritos defendem não mede nada.

Um incidente, declarado: a primeira execução completou as 120 chamadas, liquidou US\$ 0,001923295 e então a análise quebrou com KeyError: 'kind' - um campo que só existe nos corpora antigos. **Os dados se perderam inteiros,** porque nada era gravado em disco: o request_path que o executor registra no livro-caixa é só um rótulo. O custo permanece no livro-caixa, como tem de permanecer, e o experimento passou a gravar cada resposta assim que ela chega. Entre as duas execuções não mudou corpus, gabarito nem prompt - só o código de persistência.

O resultado, nos dois gabaritos:

Gabarito	Jev	llama-3.1-8b	Diferença	IC95
Meu	1,0000	0,8667	13,3%	[5,0%; 21,7%]
Anotador independente	0,8333	0,8667	-3,3%	[-10,0%; 3,3%]

Sob o meu gabarito, só o Jev acerta em 8 casos e só o comparador em nenhum (McNemar exato $p = 0,0078$).
Sob o do anotador independente, 2 contra 4 ($p = 0,6875$).

Erro grave (cancelar indevido), recontado sob os três gabaritos porque a décima quinta rodada de revisão mostrou que a afirmação anterior era falsa:

Gabarito	Jev	llama-3.1-8b
Meu e adjudicado	0	1 (dsp-d03-01)
Anotador independente	0	0

Até esta rodada, esta seção dizia que o erro grave era **"a única métrica do E11 em que a diferença não depende do gabarito"**. **Não é**. O único falso-cancelar do comparador é justamente dsp-d03-01, que está entre os 10 casos em disputa: o anotador independente leu cancelar ali, e sob o gabarito dele o comparador acerta e o erro grave some. A frase antiga usava como âncora um caso que o próprio parágrafo seguinte declara contestado. O que se sustenta é mais modesto e continua valendo: **o Jev não cometeu erro grave sob nenhum dos três gabaritos**, e o comparador cometeu sob dois deles.

Uma ressalva de contabilidade, da mesma rodada: o campo `erros_graves_cancelar` gravado nos relatórios soma cancelar indevido e cancelar perdido, e por isso marca 2 para o comparador onde a prosa diz 1. Os dois números estão certos em definições diferentes, e a definição que o pré-registro do E1 chamou de irreversível é só a primeira. O bloco `erro_grave` do relatório traz as duas listas separadas, nominalmente.

Os 10 casos em que o anotador independente discorda de mim: dsp-d01-02, dsp-d03-01, dsp-d06-03, dsp-d09-01, dsp-d10-03, dsp-d11-01, dsp-d12-01, dsp-d16-01, dsp-d16-02 e dsp-d18-01. Em **todos** eles o Jev responde o que eu responderia. Há duas leituras para isso, e eu não tenho como escolher entre elas com o que este estudo mediu:

1. O Jev segue a rubrica escrita melhor do que um modelo de 7B segue, e o anotador é que erra - o padrão das discordâncias dele é o mesmo dos corpora anteriores, puxar para ação onde o enunciado pede informação.
2. Eu escrevi 60 casos que casam com a leitura do Jev, sem perceber, porque conheço as respostas dele desde o E1.

A segunda não é paranoia: é exatamente o que um corpus escrito pelo avaliador permite, e foi ela que sustentou a quarta recomendação deste relatório. **A seção 3.11 mostra por que ela não sobreviveu:** os 10 casos foram a um terceiro juiz cego, que confirmou meu gabarito em todos.

3.11 Os 10 desacordos do desempate foram a um terceiro juiz, e ele não hesitou

A primeira leitura deste experimento dizia que a vantagem do Jev "dependia de quem escreveu o gabarito", porque sob o gabarito do anotador independente o sinal invertia. A décima quarta rodada de revisão mostrou o defeito dessa leitura: o anotador independente é um modelo de 7B, e as 10 discordâncias dele seguem **um padrão só** - ele lê o vocabulário presente na mensagem, não o ato de fala pedido. Em dsp-d01-02 ("Será que eu deveria cancelar? Antes de decidir, me explica como funciona a multa") ele marcou cancelar; em dsp-d18-01 ("Por enquanto não cancela nada, só me manda o valor da multa") marcou cobrança. É o mesmo modo de falhar da regra congelada que o Jev supera desde o E1.

Sob a Emenda 2 do pré-registro, escrita antes da execução e com a regra de leitura declarada, os 10 casos foram ao mesmo procedimento do E8b: terceiro juiz de outro fornecedor (gpt-5.6-so1-high), cego a quem escreveu cada leitura, com as duas em ordem sorteada por semente fixa, e sem ver resposta de modelo nenhum.

Decisão do terceiro juiz	Casos
Confirmam o meu gabarito	10 de 10
Confirmam o anotador independente	0
Propuseram terceira leitura	0
Declararam ambiguidade	0

Dez de dez, sem nenhuma ambiguidade declarada. A inversão de sinal era o anotador, não o gabarito - e a emenda dizia, antes de eu saber disso, que nesse caso a leitura primária pré-registrada voltaria a valer. Voltou.

Uma ressalva sobre o McNemar, apontada na mesma revisão e procedente: ele trata os 60 casos como independentes, e eles não são - são 3 por família. O $p = 0,0078$ é **secundário** e está otimista. A métrica primária, que é o bootstrap por família, respeita o agrupamento, e é ela que sustenta a conclusão.

E uma que não procede: a revisão questionou dsp-d16-03 ("Meu cancelamento já foi processado? Se ainda não, processa agora"), com gabarito cancelar, numa família chamada "pedido de confirmação, não pedido de ação". Não é contradição, é o controle da família: dois casos dela são informacao e o terceiro tem pedido explícito de execução. Famílias com caso de contraste são o desenho de todos os corpora deste estudo, e sem elas a família mediria só a classe, não o fenômeno.

3.12 A replicação (E12): mais famílias, mais comparadores, mesma divergência

O item 1 do próximo movimento deste relatório pedia repetir o E10 **"em amostra maior, com pelo menos 30 famílias, e com dois ou três LLMs econômicos em vez de um"**. Foi feito, e é o experimento mais caro em chamadas de todo o estudo: 90 casos novos em 30 famílias declaradas antes de o primeiro caso existir, cinco braços na mesma lista e na mesma ordem, 529 tentativas registradas no livro-caixa.

O que este experimento tinha de diferente. O E11 comparou o Jev contra **um** modelo de 8B de **um** fornecedor. Vencer um modelo não é vencer a classe "LLM genérico e barato": os quatro comparadores do E12 são de quatro fornecedores (Meta, Mistral, Google e OpenAI de pesos abertos), e a regra de leitura exige que o intervalo separe de zero contra **todos** para que haja vantagem. É um teste de interseção-união, conservador por construção, e ele foi escrito assim de propósito - basta um comparador barato empatar para que a conclusão não seja favorável ao sistema avaliado.

O resultado, no gabarito oficial: o Jev acerta 0,9889 e supera os quatro, de +7,8% a +14,4%, com todos os IC95 acima de zero e McNemar exato entre $p = 0,0156$ e $p = 0,0002$. Os 10 casos em que eu e o anotador independente discordamos foram a um terceiro juiz cego, de outro fornecedor, com as leituras em ordem sorteada - e ele confirmou meu gabarito em 10 de 10, sem declarar ambiguidade em nenhum.

O resultado sob o gabarito do anotador independente: contra o llama-3.1-8b a diferença é **0,0000**, IC95 [-6,7%; 6,7%], McNemar $p = 1,0000$. Contra o mistral-nemo e o gemma o intervalo encosta em zero pelo lado de baixo. Só contra o gpt-oss-20b a vantagem sobrevive.

Por que isso importa mais do que o número favorável. O E11 já tinha encontrado essa divergência, e a explicação natural era falta de poder: 20 famílias, um comparador, intervalos largos. O E12 triplicou as famílias e quadruplicou os comparadores. Se a divergência fosse ruído amostral, ela teria encolhido. Ela não encolheu - ficou no mesmo lugar. **A conclusão deste estudo sobre o Jev depende de quem escreveu o gabarito, e mais medição não resolve isso.**

Custo por mil classificações, do livro-caixa e não de estimativa: mistral-nemo US\$ 0,005638; llama-3.1-8b US\$ 0,007520; gemma-3-12b US\$ 0,014744; Jev US\$ 0,022524; gpt-oss-20b US\$ 0,092679. O Jev é o quarto mais caro dos cinco. Se a pergunta operacional for "qual o classificador mais barato que passa no critério de erro grave", o mistral-nemo custa um quarto do Jev, não comete nenhum cancelar indevido nos 90 casos e, sob o gabarito independente, não é distinguível dele.

Erro grave, no gabarito oficial: o Jev não comete nenhum falso-cancelar nem perde nenhum cancelar. O mistral-nemo também não. O llama-3.1-8b comete 2 e perde 2; o gemma comete 2 e perde 1; o gpt-oss-20b comete 1 e perde 5. Zero observado não é zero verdadeiro: com 30 famílias, o limite superior de 95% do Jev ainda é 4,4%.

Três emendas, todas escritas durante a execução e antes de olhar qualquer acurácia:

1. **Falha de transporte não é resposta errada.** O provedor devolveu HTTP 429 em 46 chamadas do gemma. Contá-las como erro de classificação atribuiria ao comparador uma falha que é da fila do provedor. Elas foram repetidas em até três tentativas; 8 seguiram sem resposta e contam como erro dele, com o número publicado.

2. **Cobertura mínima de um braço.** Um braço com menos de 90% de respostas válidas é reportado como incompleto e sai da leitura primária. O critério foi escrito antes de calcular a acurácia do braço que motivou a dúvida, justamente para que manter ou tirar não fosse escolha pós-hoc. Ao fim, gemma ficou em 91,1% e gpt-oss em 90,0%: nenhum saiu.

3. **Teto de saída é parâmetro de transporte.** Com os 64 tokens de saída herdados do E10, o gpt-oss-20b devolve conteúdo vazio - ele gasta saída com raciocínio antes de responder. O teto subiu para 256, o braço foi reexecutado desde o primeiro caso, e as 9 chamadas feitas sob o teto insuficiente foram anuladas **da análise, não do livro-caixa**, onde seguem pagas e registradas.

A terceira emenda corrigia um erro que favorecia o sistema avaliado, e é por isso que ela foi escrita antes: sem ela, o gpt-oss apareceria com acurácia perto de zero e a "vantagem do Jev" sobre ele seria um artefato da minha configuração.

4. Mecanismo: por que funciona

A vantagem sobre as regras não vem de vocabulário maior. Vem de resolver três coisas que o casamento de palavras não resolve, e que as famílias do corpus isolam uma a uma:

1. **Quem realiza a ação.** "Minha esposa cancelou o pedido dela; o meu não chegou" contém

"cancelou" e não é um pedido de cancelamento.

2. **O estatuto da ação.** Ação negada ("não quero cancelar nada"), condicional ("se não chegar até sexta, vou querer cancelar") ou já concluída ("já cancelei pelo site") não é a ação pedida.

3. **A palavra contra o pedido.** "Solicito o estorno do aparelho com defeito: mandem um novo"

usa o léxico financeiro para pedir uma troca.

A regra congelada acerta a família 1 do piloto quase inteira e desaba nas famílias G06 e G07 do conjunto de confirmação. É essa diferença que o número +0,650 do E7 está medindo.

5. Contra-hipóteses testadas

Contra-hipótese 1: o corpus foi desenhado para o sistema ganhar

Argumento: escrevi os casos conhecendo o Jev e a regra. Um corpus assim mede o autor. **Teste executado:** E7, com 40 casos novos, pré-registrados, com o sistema já congelado. **Resultado:** a vantagem não encolheu. Mas registrei que ela cresceu por piora do comparador, não por melhora do Jev. **Parcialmente refutada, com ressalva permanente.**

Contra-hipótese 2: o gabarito está errado onde o Jev "erra"

Argumento: um anotador só define a verdade que ele mesmo vai avaliar. **Teste executado:** E8, anotador independente e cego. **Teste executado:** E8 mais a adjudicação cega dos 9 casos em disputa por um terceiro juiz. **Resultado: refutada, e refutada contra o modelo.** O terceiro juiz confirmou o meu gabarito em 8 dos 9 casos. Sob o gabarito adjudicado o Jev faz 0,9625, com três erros reais - não dois. A hipótese de que "o gabarito é que está errado onde o modelo erra" só se sustentou em um caso, o mesmo que eu já havia declarado contestável antes de ter qualquer resultado.

Contra-hipótese 3: o ganho é do formato, não do modelo

Argumento: talvez lote, ordem das opções ou distração expliquem os resultados. **Teste executado:** E2 fatorial completo, mais E2b para desconfundir posição. **Resultado:** nenhuma condição se separa (McNemar $p = 1,000$). **Refutada.**

Contra-hipótese 4: o resultado depende do provedor

Teste executado: E5, dois transportes intercalados. **Resultado:** 40/40 de concordância. **Refutada.**

Contra-hipótese 5: a acurácia cai numa distribuição de classes realista

Argumento: os corpora são quase balanceados; um canal real não é. **Teste executado:** E9, reponderação da matriz de confusão sob quatro distribuições, no gabarito oficial. **Resultado:** acurácia esperada entre 0,9502 e 0,9724 - varia pouco, porque nenhuma classe é fraca. **Refutada dentro da suposição de que a dificuldade dentro de cada classe é a mesma do corpus**, que é uma suposição grande e não testada.

6. Calibração

Medida na partição de teste (conjunto de confirmação), que é a leitura honesta:

Corte	Aceitos	Cobertura	Erros observados	Limite superior de erro (por família)
0,90	35/40	87,5%	0	25,9%
0,95	34/40	85,0%	0	25,9%
0,99	28/40	70,0%	0	25,9%

O limite do corte 0,90 - **o que a seção 1 recomenda** - não estava calculado até a décima segunda rodada de revisão apontar a lacuna: o painel vendia um corte cujo número desconfortável ninguém tinha computado. Ele é **25,9% por família** e 8,2% por caso, sobre 10 famílias e 35 casos aceitos.

Zero erro observado não é taxa de erro zero. Os aceitos vêm de um número pequeno de famílias, e famílias são a unidade de dependência. O limite por caso (Clopper-Pearson, 35 ensaios no corte 0,90) daria um número bem menor, e seria enganoso: trataria casos da mesma família como observações independentes, o que eles não são.

7. Custo e operação

Medido: 1.474 chamadas, US\$ 0,035707114 no total, contra um extrato de provedor de US\$ 0,034640289 - a diferença é o arredondamento para cima que o executor aplica em toda conversão. Custo por decisão individual ~US\$ 0,000024. Latência mediana 396 ms no OpenRouter.

O E12 sozinho responde por 529 dessas chamadas e US\$ 0,013088340, e foi ele que expôs o defeito descrito na seção 9: liquidar uma requisição recusada por limite de taxa pelo pior caso fazia o livro-caixa declarar US\$ 0,499 de gasto que o provedor nunca cobrou.

Declarado, não medido: 2 minutos por revisão humana, US\$ 12,00 por hora. Nenhum cronômetro foi usado; trocar esses parâmetros muda toda a tabela abaixo.

A tabela abaixo usa a **união dos 80 casos**, que é a leitura conservadora: a partição de confirmação sozinha dá cobertura maior no mesmo corte (87,5% contra 80,0%) e, por isso mesmo, custo menor (US\$ 0.050 contra US\$ 0.080). **Cobertura e custo têm de ser lidos sempre na mesma partição** - foi essa mistura que a décima rodada de revisão encontrou no painel.

Política	Cobertura automática	Erros entre aceitos	Custo por decisão	Economia
Revisar tudo	0%	-	US\$ 0,400	-
Corte 0,99	66,25%	0	US\$ 0,135	66,2%
Corte 0,95	77,5%	0	US\$ 0,090	77,5%
Corte 0,90	80,0%	0	US\$ 0,080	80,0%
Aceitar tudo	100%	3	US\$ 0,000022	100%

A linha "aceitar tudo" é o que a automação total custaria e o que ela erraria. A diferença entre ela e o corte 0,90 é o preço de não errar: **US\$ 0,08 por decisão nesta tabela, que é a união**. Na partição de confirmação, que é a leitura da seção 1, esse preço é US\$ 0,05. Os dois números são da mesma política em bases diferentes, e nenhum dos dois deve ser citado sozinho.

8. Limites - o que este estudo não autoriza afirmar

1. **Não é um teste em dados reais.** Os 80 casos de triagem e os 24 de evidência foram

construídos por mim. Nenhum veio de um canal de atendimento em produção.

2. **Nenhum anotador humano além de mim.** O E8 mitigou com um anotador independente e o E8b

com um terceiro juiz, mas os três são modelos de linguagem. O kappa de 0,8420 sobre os 230 casos anotados mede que a rubrica é **reprodutível por um LLM**, não que ela seja válida. Os 3 erros que restam no gabarito adjudicado (tri-f02-04, tri-f06-02, tri-f09-04) passaram pela adjudicação cega, mas a adjudicação foi feita por máquina. A validade do constructo continua aberta, e é o item 2 da seção 10.

(Até a décima terceira rodada este item dizia "dois dos quatro erros do Jev podem ser erro meu" - número anterior à adjudicação, e afirmação que a seção 3.6.1 já havia substituído. Os dois textos conviveram por treze revisões, cada um dizendo uma coisa sobre o ponto que decide se o modelo erra ou se o rótulo erra.)

3. **Amostra pequena.** 10 famílias por corpus. O bootstrap respeita o agrupamento, e por isso

os intervalos são largos - o que é honesto, não um defeito.

4. **O modelo não é determinístico.** Confirmado com o caso isolado e repetido.

5. **Tempo humano não foi cronometrado.** A tabela da seção 7 é uma conta de sensibilidade, não

uma medição de fluxo real. Isso era a pergunta P5 do plano e continua aberta.

6. **confidence não foi validado como probabilidade.** Foi validado como *ordenador*: separa

bem o que está certo do que está errado nestes 80 casos. Não é a mesma coisa.

7. **Todos os anotadores deste estudo são modelos de linguagem, ou sou eu.** O gabarito do

autor é meu; o anotador independente é qwen2.5:7b; os terceiros juízes são gpt-5.6-sol-high. A adjudicação cega resolve disputas *dentro* da rubrica, e resolveu: 18 dos 19 casos em disputa no estudo inteiro foram para o meu gabarito. O que ela não pode resolver é se a rubrica corresponde ao que uma pessoa do atendimento faria. Esta é a limitação de que todas as outras derivam.

8. **Os dois braços não usam o mesmo protocolo.** O Jev responde pelo endpoint de decisões do

provedor, com o campo questions nativo; o comparador responde por chat/completions, com JSON forçado, max_tokens 64 e temperature 0. O texto da rubrica é idêntico, a interface não é, e nenhuma ablação cruzada foi feita (o comparador no endpoint de decisões, ou o Jev pelo chat). Parte da diferença medida pode ser de formato, e este estudo não separa as duas coisas.

9. **A vantagem medida é sobre um corpus de armadilhas, não sobre uma amostra de trabalho.**

As 20 famílias do E11 são a instrução congelada fatiada em fenômenos: ação de terceiro, negada, condicional, já concluída, irônica, truncada. Um canal real não chega com 20 fenômenos linguísticos × 3 casos, balanceados e escritos para punir casamento lexical. Os 13,3 pontos percentuais de diferença medem **densidade de**

armadilha, e o 60/60 do Jev é teto de escala, não façanha. O mesmo vale, e a seção 3.1 já registra, para a folga contra as regras congeladas: famílias inteiras foram desenhadas contra elas.

10. Um único LLM econômico foi testado como comparador. O E10 usou

meta-llama/llama-3.1-8b-instruct. Um empate com ele não é empate com a categoria, e uma vantagem sobre ele também não seria vantagem sobre a categoria. O que o E10 estabelece é que **um** modelo barato foi vencido neste corpus, e não que a categoria toda perca.

11. Nenhuma conclusão sobre os outros 14 sistemas do plano. A rodada simples offline dos 15

sistemas mostrou 5 suítes passando, 7 falhando e 3 sem como rodar. Isso é estado de repositório, não evidência de comportamento.

9. Controle financeiro e integridade do processo

O controle de gastos foi tratado como código crítico e passou por **quinze rodadas de revisão independente**, todas conduzidas por modelos de outros fornecedores (gpt-6-astra via Codex e Grok 4.6 via Cursor); os defeitos abaixo vão até a décima terceira, e as duas últimas rodadas não encontraram defeito financeiro novo. O décimo sexto e mais caro deles não veio de revisão nenhuma: veio da execução do E12, e está descrito no fim desta seção. As quatro primeiras encontraram mais de 20 defeitos de prioridade 1, e - como o protocolo da casa prevê - as correções de cada rodada criaram defeitos novos, apanhados na rodada seguinte. Os mais graves:

- O teto era aplicado por experimento, então abrir um experimento novo abria um teto novo.
- Divergência entre o extrato do provedor e o registro local não ocupava o teto.
- Reserva e liquidação podiam usar modelos diferentes, liberando saldo inexistente.
- Respostas ausentes sumiam das métricas e inflavam a acurácia.
- O critério de significância do pré-registro original era vazio (intervalo de Wilson sobre uma proporção nunca cruza zero); foi substituído por bootstrap de famílias, em emenda.
- `CREATE TABLE IF NOT EXISTS` não adiciona coluna a tabela existente: o banco de produção ficou sem as colunas de uma correção enquanto a suíte passava, porque a suíte usava bancos novos. Só uma verificação no estado real pegou isso.
- A migração apagava o ajuste de conciliação antes de ancorar o valor, o que devolveria ao teto dinheiro que o provedor já havia cobrado.

A sexta rodada, feita já sobre o painel pronto, encontrou o defeito mais instrutivo de todos: `authorize()`

desfazia a pausa por estouro de teto. Todo runner chama `authorize()` no arranque e, como a função era um `INSERT OR REPLACE` com status fixo em `running`, bastava relançar o script para apagar a única trava que impede gasto novo depois do teto - e apagar junto as emendas registradas. A trava criada na quinta rodada não valia nada no caminho real; valia só nos testes, que a exercitavam por outro caminho.

A mesma rodada apontou que o painel havia começado a contar meia verdade: o cartão do E8 citava os dois casos em que o anotador independente apoia o Jev e omitia os dois em que ele confirma o gabarito. Corrigido no código e na seção 3.6, e é a razão de a confiança da seção 1 ter caído de 0,75 para 0,60. O texto do veredito do painel passou a ser calculado a partir dos números, em vez de prosa fixa: um texto com números escritos à

mão continua afirmando o mesmo depois que os dados mudam.

A sétima rodada revisou as correções da sexta e encontrou o que o protocolo desta casa sempre encontra: um defeito novo, criado pela própria correção. O `authorize()` corrigido deixou de apagar a pausa, mas continuava reescrevendo o teto do experimento - e como todo runner o chama com US\$ 5,00 no arranque, **uma emenda que baixasse o teto para US\$ 1,00 seria desfeita pelo próximo** `python -m executor.run_e*`, sem registro.

Agora `authorize` só reduz; ampliar exige `ampliar_teto_do_experimento(motivo, evidencia)` e nunca passa do teto da carteira.

A mesma rodada cobrou a adjudicação dos 9 casos em disputa do E8, e a cobrança estava certa: dois anotadores que discordam não produzem verdade. A adjudicação foi feita (seção 3.6.1) e **mudou o resultado contra o modelo**, não a favor.

Conciliação de encerramento contra o extrato do provedor: o ledger registra US\$ 0,017182296 para o OpenRouter; o provedor cobrou US\$ 0,017095092. O ledger está **acima** do extrato em US\$ 0,000087, e a diferença é explicada: são as chamadas que voltaram HTTP 400 na fase de sondagem do contrato, provisionadas aqui e não cobradas lá. Nenhum excedente a absorver, nenhum gasto sem identidade de provedor. Somando o TypeSafe direto (US\$ 0,000992166), o total comprometido era US\$ 0,022618774 naquele momento; depois do E12 e da retificação descrita em 9.1, ele é US\$ 0,035707114, contra um extrato de US\$ 0,034640289.

A oitava rodada não encontrou defeito financeiro novo - o teto passou a ser, nas palavras do revisor, "o pedaço mais honesto do repositório". Encontrou coisa pior no painel: depois de adjudicar o gabarito, **o placar passou a se contradizer**. O veredito citava 87,5% em 40 casos da confirmação e o cartão ao lado citava 80% em 80 casos da união; um cartão do E8 dizia 3 erros e o outro dizia 4; e as pendências continuavam pedindo a adjudicação que o painel acabara de anunciar. Três gabaritos circulavam ao mesmo tempo e cada parte usava o que tinha à mão.

A correção não foi cosmética: `executor/gabarito.py` passou a definir **um** gabarito oficial (o do autor, com os casos em disputa substituídos pela adjudicação), o E9 passou a consumi-lo, cada cartão declara qual gabarito está por trás do seu número, e `politica_de_referencia()` devolve uma leitura só - sem cair silenciosamente na união quando a partição falta. O teste `test_coerencia_placar.py` roda o painel contra os relatórios reais e falha se veredito e cartão divergirem.

A nona rodada não achou defeito financeiro - e achou, de novo, o painel falando duas línguas. O cartão do E7 estampava 97,5% (gabarito do autor) e narrava, na linha de baixo, que no gabarito oficial não havia erro nenhum; a nota de confiança justificava o corte de 0,90 com 80 casos da união enquanto o veredito, ao lado, falava de 40 casos da confirmação. A correção da oitava tinha unificado o par que a revisão apontou com o dedo, e só ele.

Agora `executor/gabarito.py` recalcula cada conjunto **sob os dois gabaritos, na mesma conta**, e o cartão mostra a **faixa** - 97,5% a 100,0% no E7 - em vez do melhor dos dois. Com um número só, o olho pega o mais alto e a ressalva vira letra miúda. A nota de confiança passou a citar a mesma base da política que recomenda, e o título do veredito usa a mesma função de política do resto do painel.

A décima rodada não achou defeito financeiro e achou uma promessa impossível no painel: o veredito oferecia **a cobertura da partição de confirmação (87,5%) com o custo da união (US\$ 0,080)**. Custo por decisão depende da fração que vai para revisão humana, que é justamente o que a cobertura mede; as duas coisas têm de sair da mesma partição. Ou 87,5% a US\$ 0,050, ou 80% a US\$ 0,080. O meio-termo era o número preferido de cada coluna.

Corrigido: `politica_de_referencia()` passou a devolver também a política de revisar tudo da mesma partição, o veredito usa as duas, e um teste quebra se o custo da união aparecer ao lado da cobertura da confirmação. Na mesma rodada, o cartão do E8 deixou de estampar 96,2% - o mais alto dos três gabaritos - e passou a mostrar a faixa 88,8% a 96,2%, como o E7 já fazia.

A décima primeira e a décima segunda rodadas não acharam defeito financeiro; acharam o painel mostrando **dois gabaritos onde existem três**. O gabarito do anotador independente é o mais severo - no piloto dá 87,5% contra 92,5% do autor, e na confirmação 90,0% contra 97,5% - e ficava de fora dos cartões que se lê primeiro. O rótulo que deveria denunciar isso perguntava a coisa errada: se a adjudicação mudou algum caso, e não se os anotadores discordaram. Com essa pergunta, o piloto aparecia como unânime tendo quatro casos em disputa dentro dele.

A décima terceira rodada trocou de método: em vez de reler o código, **mutou os dados** e perguntou quais cartões se mexiam. Zerando as nove divergências do anotador independente dentro de `runs/e8-anotador/relatorio.json`, os cartões do E1 e do E7 acompanharam e o do E8 ficou parado. Ele não recalculava nada - lia dois agregados gravados dentro do próprio relatório no momento em que aquele experimento rodou. Era o defeito da nona rodada, número velho em caixa nova, sobrevivendo justamente no cartão que fala de gabarito. A correção criou `gabarito.desempenho_do_estudo()`, que soma E1 e E7 sob os três gabaritos na hora da leitura, e o teste de mutação virou teste permanente.

A auditoria de mutação foi então aplicada a todos os relatórios, e achou um **segundo** cartão cego: o E3 lia o bloco `jev` gravado no alto de `runs/e3-evidencia/relatorio.json` em vez de contar os casos. Os dois números batem hoje - 23 acertos em 24 - e é justamente por isso que nenhum teste de coerência podia pegá-lo: um número congelado parece correto enquanto ninguém mexe nos dados. Trocados cinco acertos por erros, o cartão continuava estampando 95,8%. Hoje ele recalcula e a auditoria de mutação virou teste permanente sobre todos os relatórios que têm lista de casos.

A mesma rodada achou um defeito que nenhum teste do painel podia achar, porque não estava no painel: `output/pdf/PLANO-CIENTIFICO-JEV-HELENA.pdf` e `output/pdf/RELATORIO-FINAL-JEV.pdf` **eram o mesmo arquivo**, byte a byte, e já tinham sido versionados assim. O gerador do relatório chamava a função que monta o PDF do plano e copiava o resultado; aquela função gravava sempre no caminho do plano e montava sempre a capa do plano. Cada build do relatório destruía o plano, e o relatório que foi entregue abria anunciando `"ensaios dos sistemas ainda pendentes"` - depois de todos os ensaios terminados. Capa e destino passaram a ser do chamador, o relatório ganhou capa própria com números vindos do placar, e dois testes novos exigem que cada PDF abra no documento que o nome dele promete.

A mesma décima terceira rodada cobrou quatro coisas que eu podia verificar e uma que eu podia executar. As quatro: o pré-registro do E1 mandava reportar erro grave separado da acurácia média, e isso nunca tinha sido feito (seção 3.7); o `runs/ledger.sqlite3` é ignorado pelo Git, e sem ele o custo publicado era uma citação que ninguém de fora podia conferir (agora `runs/extrato-ledger.json` vai versionado); o `.gitignore` tinha `runs/` puro, e como o Git não desce em diretório excluído **nenhuma** das exceções abaixo dele valia; e o README dizia "nove rodadas" enquanto este documento dizia treze.

A quinta foi a que importou. O revisor apontou que o único comparador do estudo era uma regra congelada que eu mesma escrevi, e que a pergunta P1 do plano seguia sem metade da resposta. Executei o E10 (seção 3.8), com regra de decisão congelada antes da primeira chamada. O resultado contrariou a recomendação que este documento vinha fazendo desde a primeira versão, e a recomendação mudou. Custou US\$ 0,000358, e as treze revisões adversariais feitas até ali não o teriam encontrado, porque nenhuma delas estava olhando para fora do que já havia sido medido.

O E10 e o E10b abriram uma divisão que nenhum dos dois podia fechar, e o E11 foi escrito para fechá-la: corpus novo, 20 famílias declaradas antes do primeiro caso, regra de decisão congelada antes de existir dado. Ele fechou, mas não onde eu esperava. A vantagem do Jev sobre o comparador barato é nítida sob o meu gabarito e some sob o do anotador independente - mesma execução, mesmas respostas, mesmos 60 casos.

Três defeitos apareceram no caminho e estão corrigidos: a primeira execução do E11 perdeu 120 chamadas pagas porque nada era persistido; `titulo_do_veredito` tinha virado impura e passou a responder pelo repositório em vez de responder pelos dados que recebia; e o run de tentativas órfãs se substituíu a cada publicação, apagando as próprias órfãs e desfazendo em silêncio a reconciliação de custo que a oitava rodada tinha estabelecido.

A décima quarta rodada foi a mais útil de todas, e foi a que me corrigiu contra mim mesma. Ela mostrou que eu havia enterrado um resultado pré-registrado usando como ouro um modelo de 7B cujo modo de errar é justamente o que o sistema avaliado supera; que o procedimento para resolver isso já existia no próprio estudo, o terceiro juiz cego do E8b, e que o E11 tinha parado antes dele. Rodei, sob emenda com a regra escrita antes, e o juiz confirmou meu gabarito em 10 de 10. A recomendação mudou pela quinta vez.

A mesma rodada achou três números velhos que conviviam com os novos no texto canônico - 625 chamadas e US\$ 0,018174462 na seção 7, na seção 9 e no README - e um kappa publicado que era anterior à ampliação do E8. O teste que existia exigia que o número certo aparecesse; não exigia que o errado sumisse. Agora exige.

A décima quinta rodada não encontrou defeito financeiro, e encontrou o documento ainda argumentando a recomendação anterior enquanto a seção 1 publicava a nova: a 3.10 se intitulava `"por que ele não desempatou"` e fechava dizendo que o relatório `"não fecha a favor de ninguém"`. Achou também uma afirmação que eu havia acabado de escrever e que era falsa - a de que o erro grave seria a métrica que não depende do gabarito. O único falso-cancelar do comparador está entre os 10 casos em disputa, e sob o gabarito do anotador independente ele desaparece. Reconto agora sob os três, e o que sobra é mais modesto.

9.1 O defeito que quinze rodadas de revisão não acharam, e que a execução achou

Nenhuma execução anterior deste estudo havia levado HTTP 429. O E12 levou 76.

A regra do executor é liquidar pelo pior caso reservado quando não há `usage` confiável na resposta - e ela é correta: na dúvida, o teto sofre. Uma requisição recusada por limite de taxa não tem `usage`, então cada uma das 76 entrou no livro-caixa por US\$ 0,0066. Somaram **US\$ 0,499**: mais de vinte vezes o gasto de todo o estudo até aquele momento, e 10% do teto autorizado inteiro, por chamadas em que **nenhum token foi processado**.

O extrato da chave mostrava US\$ 0,0346 de uso acumulado. As 76 foram retificadas para zero pelo mecanismo que já existia para isso (`retificar_liquidacao`, que só aceita corrigir liquidação conservadora e exige motivo e evidência), com o extrato como evidência, e a regra foi corrigida na origem: **HTTP 429 liquida zero**, porque o provedor recusa antes de gerar. A exceção vale só para o 429 - em 5xx e em timeout a geração pode ter acontecido, e ali o conservador continua certo.

Não era um erro de arredondamento: era o executor financeiro inventando meio dólar de gasto que nunca existiu. Como a política é conservadora, ele errava para o lado seguro do teto e para o lado errado da verdade - e teria bloqueado orçamento real de trabalho futuro.

Outros três defeitos apareceram na mesma execução e estão corrigidos, todos com teste:

- O interpretador de resposta do comparador assumia objeto JSON. Um modelo devolveu uma **lista** e a execução inteira caiu com `AttributeError`, depois de 361 chamadas pagas. Resposta fora do contrato é erro do comparador; agora ela vira erro, e não exceção.

- A marca que anula da análise as chamadas feitas sob teto de saída insuficiente viajava junto no registro da reexecução e apagava também a **resposta nova**. Nove chamadas já pagas do gpt-oss-20b sumiram da análise sem que nada acusasse - e sumiram justamente inflando a vantagem do Jev sobre aquele braço, de +14,4% para +24,4%. Corrigido, o número voltou a +14,4%.
 - O custo publicado no painel e no relatório do E12 vinha do valor que cada caso guardou no instante da chamada, e não do livro-caixa. Depois da retificação, os dois divergiam em US\$ 0,052 - os dois números de custo no mesmo painel que a oitava rodada já havia proibido. Agora ambos leem `attempt_budget`.
- Estado final: **1.474 tentativas, nenhuma reserva pendente sem liquidação, US\$ 0,035707114 de US\$ 5,00, conciliado contra um extrato de US\$ 0,034640289, e 173 testes automatizados passando**. A chave da API nunca foi versionada, impressa em log ou copiada para documentação.

10. Próximo movimento

1. ~~**Repetir o E10 em amostra maior**, com pelo menos 30 famílias, e com dois ou três LLMs econômicos em vez de um.~~ **Feito: é o E12, seção 3.12**. 30 famílias, quatro comparadores, US\$ 0,013. O resultado fecha a pergunta que este item fazia e abre outra: sob o gabarito adjudicado o Jev vence os quatro; sob o gabarito independente ele empata com o mais barato deles. Mais medição não separa essas duas leituras, porque a diferença entre elas não é de amostra.
 2. **Coletar 200 mensagens reais de um canal de atendimento**, com a distribuição de classes que o canal tem - responsável: Igor; critério: corpus anonimizado disponível em `data/corpus/`. **Este é agora o item que bloqueia todos os outros**: enquanto o rótulo for meu, cada experimento novo só acrescenta precisão a uma medida cuja referência não foi validada.
 3. **Anotar com dois humanos independentes** e medir kappa entre eles antes de olhar o modelo - critério: kappa humano-humano $\geq 0,80$; abaixo disso, o problema é a definição das classes, não o modelo.
 4. **Rodar a política do corte 0,90 em sombra** sobre esse corpus real, sem efeito em produção, medindo cobertura e erro entre aceitos - critério: erro entre aceitos $\leq 1\%$ com cobertura $\geq 70\%$.
 5. **Cronometrar o fluxo humano** durante a sombra, para fechar a pergunta P5 com dado medido em vez de parâmetro declarado.
 6. **Só então** decidir se a política sobe para produção, e com qual corte.
- O item 1 está fechado. Os itens 2 e 3 dependem de gente, não de orçamento, e são o caminho crítico. Restam US\$ 4,96 do teto autorizado, o que cobre com folga toda a fase de sombra - e a folga não é o que falta.

O estudo que eu queria ter feito é o que começa no item 2. O que está aqui é o que dá para saber sem dados reais - e o principal valor dele é ter descoberto, antes de gastar, exatamente onde o modelo quebra: no mesmo caso, perguntado duas vezes. O E12 acrescentou o segundo achado dessa natureza, e ele é sobre o método e não sobre o modelo: quando a conclusão depende de quem escreveu o gabarito, triplicar a amostra não a torna menos dependente - só mais precisa dentro de cada gabarito.

- **Helena.** Café preto, sem açúcar.