

Testamos todos. Este é o resultado.

Vantagem do Jev sobre o LLM econômico no gabarito adjudicado, com a validade do rótulo ainda em aberto.

80 casos	88,8% a 96,2%	US\$ 0,022618774
Piloto e confirmação, famílias distintas	Faixa entre os três gabaritos concorrentes	Gasto acumulado dentro do teto de US\$ 5

Veredito

O desempate foi feito e decidiu. Em corpus novo de 60 casos e 20 famílias, com as famílias declaradas antes de o primeiro caso ser escrito, o Jev supera um LLM genérico e barato por 13,3%, IC95 [5,0%; 21,7%], McNemar exato $p = 0,0078$, no gabarito adjudicado. O anotador independente discordava de mim em 10 casos e sob o gabarito dele a diferença era -3,3% — mas esses 10 casos foram a um terceiro juiz cego, com as leituras em ordem sorteada, e ele confirmou meu gabarito em 10 de 10. O que isto autoriza dizer é que o Jev vence este comparador neste corpus. O que continua sem resposta é se a rubrica mede o que diz medir: os três anotadores do estudo são modelos de linguagem, e nenhum deles é uma pessoa do atendimento real.

Confiança 0,35 em 1,0, por descontos declarados. Os motivos de cada desconto estão no painel e na seção 9.

19 de setembro de 2026

Todos os números deste documento são recalculados a partir dos relatórios em runs/ e do livro-caixa; nenhum é digitado à mão.

Mapa de leitura

1. Recomendação	3
2. Achado principal	5
3. Evidência	6
4. Mecanismo: por que funciona	13
5. Contra-hipóteses testadas	14
6. Calibração	15
7. Custo e operação	15
8. Limites - o que este estudo não autoriza afirmar	16
9. Controle financeiro e integridade do processo	17
10. Próximo movimento	20

Comece pelas seções 1 e 3. O método está nas seções 2 e 4 a 6. As ressalvas, o que não foi testado e o histórico de revisão fecham o documento.

Autoria: Dra. Helena Strategos, Cientista-Chefe de Inteligência da INTEIA **Execução:** 18-19 de setembro de 2026 **Sistema avaliado:** Jev 1.13 (typesafe/jev-1.13 via OpenRouter e jev-1.13.0 direto) **Custo total:** US\$ 0,022618774 em 945 chamadas, de um teto autorizado de US\$ 5,00 **Código, dados e registros:** este repositório, com pré-registros em `planning/` e relatórios brutos em `runs/`

1. Recomendação

O Jev supera um LLM genérico e barato nesta tarefa, em corpus novo e pré-registrado, sob o gabarito adjudicado por um terceiro juiz cego. O que este estudo ainda não sustenta é a validade do rótulo contra o qual todos os números foram medidos - e essa é a única pergunta que falta.

Esta é a **quinta** versão da recomendação deste relatório, todas do mesmo dia, e vale registrar a sequência porque ela é o método:

1. **"Use o Jev com corte de confiança em 0,90"** - antes de existir qualquer comparador que não fosse uma regra que eu mesma escrevi.
2. **"Não adote"** - quando o E10 comparou o Jev a `meta-llama/llama-3.1-8b-instruct` na partição de teste e a diferença não separou de zero.
3. **"Evidência dividida"** - quando o E10b, no piloto, separou.
4. **"O gargalo é o rótulo"** - quando o E11, em corpus novo, deu vantagem clara sob o meu gabarito e sinal invertido sob o do anotador independente.
5. Esta, quando os 10 desacordos do E11 foram a um terceiro juiz cego e ele **confirmou meu gabarito em 10 de 10**.

O resultado do desempate, nos três gabaritos:

Gabarito	Jev	llama-3.1-8b	Diferença	IC95	McNemar
Adjudicado (oficial)	1,0000	0,8667	13,3%	[5,0%; 21,7%]	p = 0,0078
Meu, sem adjudicar	1,0000	0,8667	13,3%	[5,0%; 21,7%]	p = 0,0078
Anotador independente	0,8333	0,8667	-3,3%	[-10,0%; 3,3%]	p = 0,6875

Por que a quarta versão estava errada, e quem mostrou isso. A décima quarta rodada de revisão adversarial apontou que eu havia enterrado um resultado pré-registrado usando como ouro um modelo de 7B cujas discordâncias seguem um padrão conhecido: classificar pelo **vocabulário presente** na mensagem em vez do ato de fala pedido - que é exatamente o modo de falhar da regra congelada que o Jev supera desde o E1. E apontou que o E8 tinha um procedimento para isso, o terceiro juiz cego, e que o E11 havia parado antes dele. Os dois pontos procedem. Escrevi a emenda com a regra de leitura **antes** de rodar o juiz, declarando que se ele confirmasse meu gabarito a conclusão mudaria contra a que eu acabara de publicar. Ele confirmou 10 de 10, sem nenhum caso em que declarasse ambiguidade ou propusesse terceira leitura.

O que isto autoriza afirmar: neste corpus, com esta rubrica e contra este comparador, o Jev é melhor, e a diferença é grande o bastante para sobreviver ao agrupamento por família. No erro grave (cancelar indevido) o **Jev não cometeu nenhum sob nenhum dos três gabaritos**; o comparador cometeu um sob dois deles e nenhum sob o terceiro - o detalhe está na seção 3.10, e ele é menos favorável do que a versão anterior desta frase dizia.

O que isto não autoriza: que a rubrica meça o que diz medir. Os três anotadores deste estudo - eu, o anotador independente e o terceiro juiz - produzem rótulos, e dois deles são modelos de linguagem enquanto o terceiro sou eu, que escrevi o corpus. Concordância entre modelos sobre uma rubrica que eu redigi mede reprodutibilidade, não validade. Enquanto duas pessoas do atendimento real não anotarem os mesmos casos e medirem kappa entre si antes de olhar qualquer modelo, toda conclusão deste relatório repousa sobre um rótulo não validado. É o item 3 da seção 10, custa tempo de gente e não custa orçamento.

(Registro de método: nenhuma das cinco versões foi apagada, e três delas contrariaram o que eu tinha acabado de publicar. A quarta foi corrigida por uma crítica externa que eu poderia ter ignorado - ela dizia que meu rigor tinha virado o seu contrário, e estava certa.)

1.1 A política de corte, que continua válida no que ela mede

O restante desta seção descreve a política de aceitação estudada no E9. **Ela não é uma recomendação de adoção, e não deve ser lida como uma.** O corte de 0,90 nunca foi pré-registrado: foi lido nos erros do piloto e depois avaliado sobre os mesmos erros, o que a seção 8 já registra ao dizer que *confidence* foi validado como ordenador e não como probabilidade. Ela está aqui porque mede uma coisa real - quanto do volume um corte cobre e ao custo de quê -, e essa medida é útil para desenhar o piloto em sombra do item 4 da seção 10. Usá-la como política operacional exigiria pré-registrar o corte num corpus que ele não tenha visto.

A política concreta que os dados sustentam: aceitar automaticamente as decisões com confiança $\geq 0,90$ e encaminhar o restante para uma pessoa. Na partição de confirmação - os 40 casos que não guiaram o desenho, que é a leitura que vale para decidir - essa política aceita **87,5%** sem nenhum erro observado entre os aceitos; na união dos 80 casos, aceita 80%, também sem erro observado. Os erros do modelo - quatro no gabarito do autor, três no oficial - têm todos confiança abaixo de 0,90.

A base é pequena e o número precisa ser lido assim: são 3 erros em 80 casos no gabarito oficial (4, no do autor). "Nenhum erro entre os aceitos" descreve o que foi observado, não uma garantia; a seção 6 traz o limite superior que sobra depois de respeitar o agrupamento por família. Sob os parâmetros da seção 7 - declarados, nunca cronometrados - e **na mesma partição de confirmação**, a política leva o custo por decisão de US\$ 0.400 para US\$ 0.050. Na união dos 80 casos, onde a cobertura cai para 80%, o mesmo corte custa US\$ 0.080. Citar a cobertura de uma partição com o preço da outra descreveria uma política que não existe.

O que impede a recomendação de ir além disso: o modelo não é determinístico. O mesmo caso, sozinho e repetido cinco vezes, pode mudar de resposta. Um sistema que decide sozinho precisa responder igual à mesma pergunta, e este não responde.

Acurácia do modelo nestes 80 casos: entre 0,8875 e 0,9625, conforme o gabarito adotado - 0,8875 sob o gabarito do anotador independente, 0,95 sob o meu, e 0,9625 sob o adjudicado, que é o oficial **porque foi declarado antes**, não porque é o mais alto. Reportar só o número mais alto seria escolher o gabarito depois de ver o resultado, e é por isso que o painel exibe a faixa.

*(Correção registrada na décima terceira rodada: até aqui esta frase chamava o adjudicado de "o mais defensável dos três". A revisão adversarial apontou que essa é exatamente a manobra que o resto do

documento condena - o adjudicado dá o teto da faixa, e dois dos três anotadores que o produziram passaram pela minha mão. O único gabarito que não passou é o do anotador independente, que dá o piso, 0,8875. Nenhum dos três é "o mais defensável"; o que existe é a faixa.)*

(Correção registrada: até a décima primeira rodada de revisão, este parágrafo dizia "entre 0,8875 e 0,9750". O 0,9750 não é gabarito nenhum destes 80 casos - é a acurácia do E7 isolado, que tem 40. Misturar denominadores é o mesmo vício que eu vinha corrigindo no painel, e ele estava aqui.)

Confiança: 0,35. Este número deixou de ser um julgamento meu e passou a ser uma conta com as penalidades declaradas, partindo de 1,0:

- a política se apoia em 40 casos, menos de cem (-0,20)
- 1 caso(s) mudam de resposta entre repetições idênticas (-0,10)
- o gabarito foi adjudicado por modelos, não por pessoas do domínio (-0,10)
- corpus construído pelo avaliador, não colhido de uso real (-0,10)
- zero erro observado entre os aceitos, mas o limite superior de 95% por família é 25,9% (-0,10)
- o comparador econômico foi vencido no gabarito adjudicado, mas os três anotadores que produziram esse gabarito são modelos de linguagem (-0,05)

Os dois últimos descontos entraram na décima terceira rodada, cobrados pela revisão adversarial: o teto de erro já estava escrito na seção 6 e não era descontado, e o braço do LLM econômico não existia. Depois que ele passou a existir e empatou, o desconto por ausência de comparador (-0,10) virou desconto por comparador que não separou de zero (-0,20). A nota caiu de 0,5 para 0,2 sem que nenhum dado do Jev piorasse: o que mudou foi o que se sabe sobre a alternativa. A conta está em `executor/placar.py:confianca_calculada`, e é para ser contestada: se alguém achar que um desconto está errado, o lugar de discutir é o código, não a minha impressão.

2. Achado principal

A confiança que o modelo reporta é informativa, e essa é a descoberta com mais valor operacional do estudo.

Não era óbvio. `confidence` é um número que o modelo emite sobre a própria resposta; nada garante que corresponda a probabilidade de acerto. Mas nos dois corpora, todos os erros ficaram concentrados abaixo de 0,90, e nenhum caso aceito acima desse corte estava errado. É isso que torna viável uma política de triagem com revisão seletiva, em vez de revisão total.

A ressalva é grande e vai na seção 8: zero erro entre os aceitos não é taxa de erro zero. Respeitando o agrupamento por família, o limite superior do erro ainda chega a 25,9%.

3. Evidência

3.1 Comparação contra comparadores congelados

Os três primeiros resultados abaixo usam o **gabarito do autor**, como pré-registrado. O gabarito oficial do estudo, depois da adjudicação da seção 3.6.1, está na seção 3.6 e move os números para cima; mantenho os dois porque trocar de gabarito depois de ver o resultado é exatamente o que um pré-registro existe para impedir.

Experimento	Jev	Comparador	Diferença pareada (IC95, bootstrap de famílias)
E1 triagem, piloto (40 casos, 10 famílias)	0,925	regra de palavras-chave 0,600	+0,325 [0,150; 0,500]
E3 suporte por evidência (24 casos, 6 famílias)	0,958	regra ingênua 0,625	+0,333 [0,250; 0,417]
E7 triagem, confirmação (40 casos, 10 famílias)	0,975	mesma regra congelada 0,325	+0,650 [0,525; 0,775]

O E7 é o experimento que mais importa: 40 casos escritos **depois** de o sistema estar congelado, pré-registrados, projetados para armadilhas que o piloto não cobria. A vantagem não encolheu fora do piloto - que era o risco real de um estudo desenhado pelo próprio avaliador.

Ressalva registrada em emenda ao pré-registro, antes de aparecer em qualquer resumo: a vantagem cresceu porque o comparador piorou, não porque o Jev melhorou. O Jev foi de 0,925 para 0,975 (dois casos); a regra caiu de 0,600 para 0,325, porque escrevi famílias inteiras contra casamento de palavras-chave. A comparação honesta entre corpora é a do Jev consigo mesmo.

3.1.1 O mesmo resultado sob os três gabaritos

Existem três gabaritos para estes casos, e eles não dão o mesmo número. Apresentar um só, sem dizer qual, foi o defeito que a décima segunda rodada de revisão encontrou no painel.

Conjunto	Anotador independente	Meu gabarito	Adjudicado	Casos em disputa
E1 piloto (40 casos)	0,875	0,925	0,925	4
E7 confirmação (40 casos)	0,9	0,975	1	5
Os 80 juntos	0,8875	0,95	0,9625	9

O gabarito do anotador independente é o mais severo dos três, e ele **não** é o menos defensável: é o único que não passou pela minha mão. Ele erra de formas próprias - em 6 das 9 divergências viu ação onde o enunciado

pedia informação - mas citar só os outros dois seria escolher o gabarito depois de ver o resultado. O painel exibe a faixa completa em cada cartão.

3.2 Ressalvas e exceções (E4)

Oito consultas, cinco candidatos cada, com ressalvas críticas plantadas. Perder uma ressalva no topo significa que a exceção não chega a quem decide.

Ordenação	Ressalvas no topo-3	nDCG@5
Jev	8/8	0,9958
BM25	5/8	0,9205
Ordem de chegada	4/8	0,7359

O corpus foi embaralhado com semente fixa antes da execução, porque na primeira versão ele estava em ordem decrescente de relevância e a "ordem de chegada" ganhava de graça.

3.3 Formato, lote e posição (E2, E2b)

Desenho fatorial $2 \times 2 \times 2$ (lote $\times$ ordem das opções $\times$ distração), 8 condições sobre os mesmos 40 casos, ordem de execução embaralhada. Acurácia entre 0,925 e 0,950; **McNemar $p = 1,000$ em todos os contrastes** - nenhuma condição se separa das outras. O lote de 8 reduz o custo por decisão em 32% a 43%.

O E2 sugeriu que as posições 4 e 8 do lote eram piores. O E2b desconfundiu: com a ordem dos casos fixa, posição e caso eram a mesma variável. Embaralhando em 5 permutações (200 observações), o efeito de posição desaparece: **permutação $p = 0,403$** . O que sobra é outro achado, que virou o E6.

3.4 Estabilidade (E2b, E6)

- **No lote:** 3 casos em 40 mudam de resposta conforme os vizinhos do lote.
- **Isolado:** com uma pergunta por chamada, repetida 5 vezes, **1 caso em 40** ainda muda de resposta entre repetições idênticas - e é um dos três.

Conclusão: parte da instabilidade é do próprio modelo, não do agrupamento. Voto majoritário de cinco chamadas leva a acurácia de 0,925 a 0,950: **um caso a mais, a cinco vezes o custo.**

3.5 Transporte (E5)

OpenRouter contra o endpoint TypeSafe direto, mesmos 40 casos, chamadas intercaladas para que uma deriva do serviço não caísse sobre um só braço.

	Concordância	Acurácia	Latência p50	Custo por decisão
OpenRouter	\-	0,925	396 ms	22,167 nusd
TypeSafe direto	40/40 (100%)	0,925	755 ms	24,804 nusd

Decisão idêntica em todos os casos. O direto é $\sim 2\times$ mais lento e $\sim 12\%$ mais caro, porque cobra tokens de saída que o OpenRouter não cobra. **Não há motivo técnico para trocar de transporte.**

3.6 Qualidade do gabarito (E8)

A limitação mais séria de todo o estudo era ter um anotador só. Um anotador independente e cego (qwen2.5-7b local, custo zero, outro fornecedor e outra arquitetura) classificou os 80 casos vendo apenas as instruções e os critérios - sem o gabarito e sem a resposta do Jev.

- **Kappa de Cohen: 0,859.** Concordância bruta 88,8%, 9 divergências em 80.

- Dos **4 erros do Jev** sob o meu gabarito, o anotador independente ****confirma o meu gabarito**

em 2 (tri-f06-02, tri-f09-04 - **erros claros do modelo**) e fica do lado do Jev em 2** (tri-f02-04, cnf-g05-02). Nas outras 7 divergências foi o anotador que caiu na armadilha, com o Jev do lado do gabarito.

- **Sob o gabarito do outro anotador, o Jev faz 0,8875, não 0,95.** A acurácia depende de qual

gabarito se adota, e é exatamente essa fragilidade que o experimento veio expor.

Um dado lateral que vale registrar: o anotador independente tinha a opção de marcar um caso como ambíguo, e marcou 6. Apenas 2 desses 6 estavam de fato entre os 9 em que ele divergiu de mim. A autopercepção de ambiguidade praticamente não previu a divergência real - o que é mais um motivo para não usar "o modelo disse que estava em dúvida" como filtro de qualidade.

3.6.1 Adjudicação cega dos 9 casos em disputa

A sétima rodada de revisão apontou, com razão, que sem adjudicação o E8 não fechava nada: dois anotadores que discordam não produzem verdade, produzem uma disputa. Os 9 casos foram então submetidos a um **terceiro juiz** (gpt-5.6-sol-high, outro fornecedor ainda), que recebeu só a mensagem e as duas leituras **em ordem sorteada**, sem saber qual veio de quem.

	Resultado
Casos em que o terceiro juiz confirma o gabarito do autor	8 de 9
Casos em que confirma o anotador local	1 de 9 (cnf-g05-02)
Casos em que propôs uma terceira leitura	0

Este resultado corrige a leitura anterior deste relatório, e corrige-a contra o modelo. Eu havia registrado que em 2 dos 4 erros "o suspeito é o meu gabarito". A adjudicação diz outra coisa: em tri-f02-04 o terceiro juiz ficou comigo, e o Jev errou mesmo. Só cnf-g05-02 - o caso que eu já havia declarado contestável antes de ver qualquer um destes resultados - mudou de lado, e mudou contra mim.

Sob o gabarito adjudicado, o Jev faz 0,9625 (77/80), com três erros: tri-f02-04, tri-f06-02 e tri-f09-04 - **todos do corpus piloto.** No conjunto de confirmação, que é a partição de teste, o gabarito adjudicado deixa o modelo **sem erro nenhum**, porque o único erro que havia lá (cnf-g05-02) foi justamente o caso que mudou de lado. Isso não deve ser lido como "40/40 no teste": é um resultado de 40 casos em que o único erro virou disputa e a disputa foi decidida por um terceiro modelo. O número que eu levaria a uma reunião é o de 80 casos, 0,9625.

A faixa honesta de acurácia nestes 80 casos é **0,8875 a 0,9625**: 0,8875 sob o gabarito do anotador independente, 0,9500 sob o meu, 0,9625 sob o adjudicado.

O limite desta adjudicação, dito antes que alguém o use contra o resultado: o terceiro juiz é um modelo de linguagem grande, como o Jev. Modelos grandes treinados em dados parecidos tendem a compartilhar a mesma convenção sobre o que é "a ação pedida" - a concordância de 8 em 9 pode estar medindo essa convenção compartilhada, e não a verdade do domínio. O desenho controla o que dá para controlar (ordem sorteada, juiz cego à autoria, nenhum acesso ao repositório), mas não controla isso. Uma adjudicação com três pessoas do atendimento real poderia chegar a outro lugar, e continua sendo o item 2 da seção 10.

Ressalva que não pode ser omitida: um modelo de 7B não é anotador humano, e o E8 **não é a adjudicação de gabarito** que o estudo precisa. Ele recebeu a minha rubrica e reproduziu a minha rubrica; kappa alto aqui mede reprodutibilidade, não validade do constructo. O padrão das divergências mostra viés claro - em 6 das 9 ele viu ação onde eu li pedido de informação, que é precisamente a armadilha que as instruções mandam evitar. E os 71 casos de "consenso" são os casos em que os dois concordam, ou seja, os fáceis: a acurácia de 0,9718 ali **não é uma medida melhor, é uma medida sobre um subconjunto mais fácil**, e não corrige nada. Os 9 casos em disputa **foram adjudicados** (seção 3.6.1), mas por um terceiro modelo, não por uma pessoa. **O anotador humano continua pendente**, e o que a adjudicação mostra é que a rubrica é reproduzível entre juízes independentes - não que ela seja a definição certa do problema.

3.7 Erro grave: cancelar indevido

O pré-registro do E1 define, desde 18 de setembro, que **erro grave é confundir cancelar com qualquer outra classe, porque cancelar dispara ação irreversível no atendimento**, e manda reportá-lo **separadamente da acurácia média**. Até a décima terceira rodada de revisão ele nunca foi reportado. A cobrança procede e é séria: acurácia média trata todos os erros como iguais, e a métrica que o próprio protocolo classificou como irreversível ficou fora do relatório inteiro.

Conjunto	Gabarito	Indevido	Perdido	Teto por família	Regra congelada
piloto (E1)	anotador local	0	2	25,9%	3
piloto (E1)	autor	0	1	25,9%	4
piloto (E1)	oficial	0	1	25,9%	4
confirmação (E7)	anotador local	0	1	25,9%	5
confirmação (E7)	autor	0	0	25,9%	6
confirmação (E7)	oficial	0	0	25,9%	6

O Jev não cometeu nenhum erro grave nos 80 casos, sob nenhum dos três gabaritos. A regra congelada comete 10. Este é o resultado mais favorável ao modelo em todo o estudo, e é exatamente por isso que o teto vai na mesma tabela: com 10 famílias por conjunto, zero erro observado só permite afirmar que a taxa por família está **abaixo de 25,9% com 95% de confiança**. Zero observado não é zero verdadeiro, e um teto de um quarto por família não é uma garantia operacional. O que este número autoriza dizer é que o erro irreversível não apareceu onde a regra congelada o comete dez vezes; o que ele não autoriza é prometer que não aparecerá.

O sentido oposto - cancelar que o modelo deixa passar - aparece em 1 ou 2 casos conforme o gabarito. Custa atraso, não destruição, e por isso está na tabela mas fora da definição de erro grave.

3.8 O braço do LLM econômico (E10)

O estudo comparou o Jev contra uma regra congelada em todos os experimentos anteriores, e a regra perde feio em toda parte: 60,0% no piloto, 32,5% na confirmação, 10 erros graves contra zero. Nada disso responde à pergunta que o plano fez primeiro: **vale um LLM especializado aqui, ou qualquer classificador de linguagem resolve?**

meta-llama/llama-3.1-8b-instruct recebeu **exatamente as mesmas instruções e os mesmos critérios congelados do E1** - sem exemplos, sem ajuste de prompt, sem nenhuma iteração contra estes casos - nos 40 casos da partição de confirmação, com temperature 0 e max_tokens 64. Custo total: US\$ 0,000358.

	Autor	Oficial	Anotador independente	Erro grave
Jev 1,13	0,9750	1,0000	0,9000	0
llama-3.1-8b	0,9000	0,9250	0,8500	0
Regra congelada	0,3250	-	-	6

Diferença pareada **7,5%**, IC95 **[0,0%; 15,0%]** sobre 10 famílias. O intervalo toca zero no limite inferior. Discordâncias: 3 casos, todos a favor do Jev - cnf-g03-01, cnf-g05-04, cnf-g07-01 -, o que dá McNemar exato bilateral **p = 0,25**.

Três detalhes de método que impedem este resultado de ser lido como favorável a quem eu quisesse:

1. **O Jev não foi reexecutado.** As respostas dele vêm do E7, dos mesmos 40 casos. Reexecutar daria ao Jev uma segunda amostragem que o comparador não teve - e, como o E6 mostrou, este modelo não é determinístico.
2. **Resposta fora do contrato contaria como erro**, nunca seria reexecutada nem descartada. Isso estava no pré-registro justamente porque descartar resposta malformada do comparador e não do Jev é uma das formas mais comuns de fraudar este tipo de comparação. Não foi preciso: as 40 respostas vieram em JSON válido, com classe dentro das cinco.
3. **O comparador não é o anotador do E8.** Usar o qwen2.5:7b aqui faria do anotador juiz de si mesmo. Ainda assim, sob o gabarito daquele anotador - o mais severo dos três - o comparador faz 0.8500 e o Jev 0.9000.

O que isto não diz: que nenhum LLM econômico resolve a tarefa (testou-se um), que os dois são equivalentes (o poder é baixo), ou que o Jev é dispensável em produção (o corpus continua sendo escrito por mim). O que diz é uma coisa só, e basta para mudar a recomendação: **este estudo não mostrou que o Jev é necessário.**

3.9 O mesmo comparador no piloto (E10b), e o que ele fez com a conclusão

O intervalo do E10 encostou em zero no limite inferior. Com 10 famílias, é o caso em que mais poder muda a leitura - e havia 10 famílias disponíveis, a US\$ 0,0004. Rodei, sob a Emenda 1 do pré-registro, escrita antes da execução.

Conjunto (famílias)	Jev	llama-3.1-8 b	Diferença	IC95
Confirmação, teste (10)	0,9750	0,9000	7,5%	[0,0%; 15,0%] - não separa
Piloto (10)	0,9250	0,7250	20,0%	[10,0%; 30,0%] - separa
Os 80, 20 famílias	0,9500	0,8125	13,8%	[7,5%; 20,0%] - separa

A assimetria é grande e merece ser dita: o comparador cai de 90,0% na confirmação para 72.5% no piloto, enquanto o Jev cai de 97,5% para 92.5%. O corpus piloto é mais duro **para o comparador**, não para os dois igualmente.

A premissa da minha própria emenda não sobreviveu à conferência. A emenda dizia que o piloto havia guiado o desenho do prompt do Jev e que por isso o resultado ali deveria ser lido como secundário. Fui ao histórico: as instruções e os critérios entraram uma única vez, no commit 9f6d13b de 18/09, junto com o corpus piloto, e nunca foram alterados; o corpus piloto também não mudou depois de rodar. Não houve iteração de prompt contra resultados. Registreii isso como nota de verificação no próprio pré-registro, em vez de reescrever a emenda.

O que continua valendo contra a leitura ampliada é outra coisa, e é suficiente: **eu escolhi rodar o piloto depois de ver o resultado primário.** Uma análise decidida depois de ver o resultado que ela vai corrigir não pode ser apresentada como se tivesse sido planejada antes - ainda que a conta esteja certa, e ela está.

Por isso o relatório não elege nenhum dos dois lados. A partição que existe para decidir não separa; a leitura com o dobro das famílias separa; e a segunda foi escolhida depois da primeira. Esta era a conclusão antes da adjudicação dos 10 desacordos. A seção 3.11 conta o que aconteceu com ela.

3.10 O desempate (E11): o que ele mediu, e o que quase me fez concluir errado

O E10 não separou de zero na partição de teste; o E10b, decidido depois, separou no piloto. Os dois defeitos eram claros: poder baixo e uma análise escolhida depois de ver a outra. O E11 existe para resolver os dois - e resolveu, só que a resposta não foi a que a pergunta esperava.

O que foi congelado antes de qualquer dado existir: as 20 famílias de fenômeno linguístico, listadas nominalmente no pré-registro; a métrica primária; o bootstrap por família; e as três leituras possíveis do intervalo, com o que cada uma obrigaria a escrever aqui. Só então os 60 casos foram escritos, três por família, com o gabarito fixado junto com o caso.

Dois correções antes da primeira chamada, pela mesma disciplina do E7: dsp-d12-02 tinha gabarito trocar num pedido condicional, e a rubrica que os dois modelos recebem diz que ação condicional não é ação pedida - o caso mediria a contradição, não o modelo; dsp-d09-02 ficava entre rastrear e informacao, e um caso que dois gabaritos defendem não mede nada.

Um incidente, declarado: a primeira execução completou as 120 chamadas, liquidou US\$ 0,001923295 e então a análise quebrou com `KeyError: 'kind'` - um campo que só existe nos corpora antigos. **Os dados se perderam inteiros**, porque nada era gravado em disco: o `request_path` que o executor registra no livro-caixa é só um rótulo. O custo permanece no livro-caixa, como tem de permanecer, e o experimento passou a gravar cada resposta assim que ela chega. Entre as duas execuções não mudou corpus, gabarito nem prompt - só o código de persistência.

O resultado, nos dois gabaritos:

Gabarito	Jev	llama-3.1-8b	Diferença	IC95
Meu	1,0000	0,8667	13,3%	[5,0%; 21,7%]
Anotador independente	0,8333	0,8667	-3,3%	[-10,0%; 3,3%]

Sob o meu gabarito, só o Jev acerta em 8 casos e só o comparador em nenhum (McNemar exato $p = 0,0078$). Sob o do anotador independente, 2 contra 4 ($p = 0,6875$).

Erro grave (`cancelar` indevido), recontado sob os três gabaritos porque a décima quinta rodada de revisão mostrou que a afirmação anterior era falsa:

Gabarito	Jev	llama-3.1-8b
Meu e adjudicado	0	1 (<code>dsp-d03-01</code>)
Anotador independente	0	0

Até esta rodada, esta seção dizia que o erro grave era *"a única métrica do E11 em que a diferença não depende do gabarito"*. **Não é.** O único falso-`cancelar` do comparador é justamente `dsp-d03-01`, que está entre os 10 casos em disputa: o anotador independente leu `cancelar` ali, e sob o gabarito dele o comparador acerta e o erro grave some. A frase antiga usava como âncora um caso que o próprio parágrafo seguinte declara contestado. O que se sustenta é mais modesto e continua valendo: **o Jev não cometeu erro grave sob nenhum dos três gabaritos**, e o comparador cometeu sob dois deles.

Uma ressalva de contabilidade, da mesma rodada: o campo `erros_graves_cancelar` gravado nos relatórios soma `cancelar indevido` e `cancelar perdido`, e por isso marca 2 para o comparador onde a prosa diz 1. Os dois números estão certos em definições diferentes, e a definição que o pré-registro do E1 chamou de irreversível é só a primeira. O bloco `erro_grave` do relatório traz as duas listas separadas, nominalmente.

Os 10 casos em que o anotador independente discorda de mim: `dsp-d01-02`, `dsp-d03-01`, `dsp-d06-03`, `dsp-d09-01`, `dsp-d10-03`, `dsp-d11-01`, `dsp-d12-01`, `dsp-d16-01`, `dsp-d16-02` e `dsp-d18-01`. Em **todos** eles o Jev responde o que eu responderia. Há duas leituras para isso, e eu não tenho como escolher entre elas com o que este estudo mediu:

1. O Jev segue a rubrica escrita melhor do que um modelo de 7B segue, e o anotador é que erra - o padrão das discordâncias dele é o mesmo dos corpora anteriores, puxar para ação onde o enunciado pede informação.
2. Eu escrevi 60 casos que casam com a leitura do Jev, sem perceber, porque conheço as respostas

dele desde o E1.

A segunda não é paranoia: é exatamente o que um corpus escrito pelo avaliador permite, e foi ela que sustentou a quarta recomendação deste relatório. **A seção 3.11 mostra por que ela não sobreviveu:** os 10 casos foram a um terceiro juiz cego, que confirmou meu gabarito em todos.

3.11 Os 10 desacordos do desempate foram a um terceiro juiz, e ele não hesitou

A primeira leitura deste experimento dizia que a vantagem do Jev "dependia de quem escreveu o gabarito", porque sob o gabarito do anotador independente o sinal invertia. A décima quarta rodada de revisão mostrou o defeito dessa leitura: o anotador independente é um modelo de 7B, e as 10 discordâncias dele seguem **um padrão só** - ele lê o vocabulário presente na mensagem, não o ato de fala pedido. Em dsp-d01-02 ("Será que eu deveria cancelar? Antes de decidir, me explica como funciona a multa") ele marcou `cancelar`; em dsp-d18-01 ("Por enquanto não cancela nada, só me manda o valor da multa") marcou `cobrança`. É o mesmo modo de falhar da regra congelada que o Jev supera desde o E1.

Sob a Emenda 2 do pré-registro, escrita antes da execução e com a regra de leitura declarada, os 10 casos foram ao mesmo procedimento do E8b: terceiro juiz de outro fornecedor (gpt-5.6-so1-high), cego a quem escreveu cada leitura, com as duas em ordem sorteada por semente fixa, e sem ver resposta de modelo nenhum.

Decisão do terceiro juiz	Casos
Confirmam o meu gabarito	10 de 10
Confirmam o anotador independente	0
Propuseram terceira leitura	0
Declararam ambiguidade	0

Dez de dez, sem nenhuma ambiguidade declarada. A inversão de sinal era o anotador, não o gabarito - e a emenda dizia, antes de eu saber disso, que nesse caso a leitura primária pré-registrada voltaria a valer. Voltou.

Uma ressalva sobre o McNemar, apontada na mesma revisão e procedente: ele trata os 60 casos como independentes, e eles não são - são 3 por família. O $p = 0,0078$ é **secundário** e está otimista. A métrica primária, que é o bootstrap por família, respeita o agrupamento, e é ela que sustenta a conclusão.

E uma que não procede: a revisão questionou dsp-d16-03 ("Meu cancelamento já foi processado? Se ainda não, processa agora"), com gabarito `cancelar`, numa família chamada "pedido de confirmação, não pedido de ação". Não é contradição, é o controle da família: dois casos dela são `informacao` e o terceiro tem pedido explícito de execução. Famílias com caso de contraste são o desenho de todos os corpora deste estudo, e sem elas a família mediria só a classe, não o fenômeno.

4. Mecanismo: por que funciona

A vantagem sobre as regras não vem de vocabulário maior. Vem de resolver três coisas que o casamento de palavras não resolve, e que as famílias do corpus isolam uma a uma:

1. **Quem realiza a ação.** "Minha esposa cancelou o pedido dela; o meu não chegou" contém "cancelou" e não é um pedido de cancelamento.
2. **O estatuto da ação.** Ação negada ("não quero cancelar nada"), condicional ("se não chegar até sexta, vou querer cancelar") ou já concluída ("já cancelei pelo site") não é a ação pedida.
3. **A palavra contra o pedido.** "Solicito o estorno do aparelho com defeito: mandem um novo" usa o léxico financeiro para pedir uma troca.

A regra congelada acerta a família 1 do piloto quase inteira e desaba nas famílias G06 e G07 do conjunto de confirmação. É essa diferença que o número +0,650 do E7 está medindo.

5. Contra-hipóteses testadas

Contra-hipótese 1: o corpus foi desenhado para o sistema ganhar

Argumento: escrevi os casos conhecendo o Jev e a regra. Um corpus assim mede o autor. **Teste executado:** E7, com 40 casos novos, pré-registrados, com o sistema já congelado. **Resultado:** a vantagem não encolheu. Mas registrei que ela cresceu por piora do comparador, não por melhora do Jev. **Parcialmente refutada, com ressalva permanente.**

Contra-hipótese 2: o gabarito está errado onde o Jev "erra"

Argumento: um anotador só define a verdade que ele mesmo vai avaliar. **Teste executado:** E8, anotador independente e cego. **Teste executado:** E8 mais a adjudicação cega dos 9 casos em disputa por um terceiro juiz. **Resultado: refutada, e refutada contra o modelo.** O terceiro juiz confirmou o meu gabarito em 8 dos 9 casos. Sob o gabarito adjudicado o Jev faz 0,9625, com três erros reais - não dois. A hipótese de que "o gabarito é que está errado onde o modelo erra" só se sustentou em um caso, o mesmo que eu já havia declarado contestável antes de ter qualquer resultado.

Contra-hipótese 3: o ganho é do formato, não do modelo

Argumento: talvez lote, ordem das opções ou distração expliquem os resultados. **Teste executado:** E2 fatorial completo, mais E2b para desconfundir posição. **Resultado:** nenhuma condição se separa (McNemar $p = 1,000$). **Refutada.**

Contra-hipótese 4: o resultado depende do provedor

Teste executado: E5, dois transportes intercalados. **Resultado:** 40/40 de concordância. **Refutada.**

Contra-hipótese 5: a acurácia cai numa distribuição de classes realista

Argumento: os corpora são quase balanceados; um canal real não é. **Teste executado:** E9, reponderação da matriz de confusão sob quatro distribuições, no gabarito oficial. **Resultado:** acurácia esperada entre 0,9502 e 0,9724 - varia pouco, porque nenhuma classe é fraca. **Refutada dentro da suposição de que a dificuldade dentro de cada classe é a mesma do corpus**, que é uma suposição grande e não testada.

6. Calibração

Medida na partição de teste (conjunto de confirmação), que é a leitura honesta:

Corte	Aceitos	Cobertura	Erros observados	Limite superior de erro (por família)
0,90	35/40	87,5%	0	25,9%
0,95	34/40	85,0%	0	25,9%
0,99	28/40	70,0%	0	25,9%

O limite do corte 0,90 - **o que a seção 1 recomenda** - não estava calculado até a décima segunda rodada de revisão apontar a lacuna: o painel vendia um corte cujo número desconfortável ninguém tinha computado. Ele é **25,9% por família** e 8,2% por caso, sobre 10 famílias e 35 casos aceitos.

Zero erro observado não é taxa de erro zero. Os aceitos vêm de um número pequeno de famílias, e famílias são a unidade de dependência. O limite por caso (Clopper-Pearson, 35 ensaios no corte 0,90) daria um número bem menor, e seria enganoso: trataria casos da mesma família como observações independentes, o que eles não são.

7. Custo e operação

Medido: 945 chamadas, US\$ 0,022618774 no total. Custo por decisão individual ~US\$ 0,000022. Latência mediana 396 ms no OpenRouter.

Declarado, não medido: 2 minutos por revisão humana, US\$ 12,00 por hora. Nenhum cronômetro foi usado; trocar esses parâmetros muda toda a tabela abaixo.

A tabela abaixo usa a **união dos 80 casos**, que é a leitura conservadora: a partição de confirmação sozinha dá cobertura maior no mesmo corte (87,5% contra 80,0%) e, por isso mesmo, custo menor (US\$ 0.050 contra US\$ 0.080). **Cobertura e custo têm de ser lidos sempre na mesma partição** - foi essa mistura que a décima rodada de revisão encontrou no painel.

Política	Cobertura automática	Erros entre aceitos	Custo por decisão	Economia
Revisar tudo	0%	-	US\$ 0,400	-
Corte 0,99	66,25%	0	US\$ 0,135	66,2%
Corte 0,95	77,5%	0	US\$ 0,090	77,5%
Corte 0,90	80,0%	0	US\$ 0,080	80,0%
Aceitar tudo	100%	3	US\$ 0,000022	100%

A linha "aceitar tudo" é o que a automação total custaria e o que ela erraria. A diferença entre ela e o corte 0,90 é o preço de não errar: **US\$ 0,08 por decisão nesta tabela, que é a união**. Na partição de confirmação, que é

a leitura da seção 1, esse preço é US\$ 0,05. Os dois números são da mesma política em bases diferentes, e nenhum dos dois deve ser citado sozinho.

8. Limites - o que este estudo não autoriza afirmar

1. **Não é um teste em dados reais.** Os 80 casos de triagem e os 24 de evidência foram construídos por mim. Nenhum veio de um canal de atendimento em produção.

2. **Nenhum anotador humano além de mim.** O E8 mitigou com um anotador independente e o E8b com um terceiro juiz, mas os três são modelos de linguagem. O kappa de 0,8301 sobre os 140 casos anotados mede que a rubrica é **reprodutível por um LLM**, não que ela seja válida. Os 3 erros que restam no gabarito adjudicado (tri-f02-04, tri-f06-02, tri-f09-04) passaram pela adjudicação cega, mas a adjudicação foi feita por máquina. A validade do constructo continua aberta, e é o item 2 da seção 10.

(Até a décima terceira rodada este item dizia "dois dos quatro erros do Jev podem ser erro meu" - número anterior à adjudicação, e afirmação que a seção 3.6.1 já havia substituído. Os dois textos conviveram por treze revisões, cada um dizendo uma coisa sobre o ponto que decide se o modelo erra ou se o rótulo erra.)

3. **Amostra pequena.** 10 famílias por corpus. O bootstrap respeita o agrupamento, e por isso os intervalos são largos - o que é honesto, não um defeito.

4. **O modelo não é determinístico.** Confirmado com o caso isolado e repetido.

5. **Tempo humano não foi cronometrado.** A tabela da seção 7 é uma conta de sensibilidade, não uma medição de fluxo real. Isso era a pergunta P5 do plano e continua aberta.

6. confidence **não foi validado como probabilidade.** Foi validado como *ordenador*: separa bem o que está certo do que está errado nestes 80 casos. Não é a mesma coisa.

7. **Todos os anotadores deste estudo são modelos de linguagem, ou sou eu.** O gabarito do autor é meu; o anotador independente é qwen2.5:7b; os terceiros juízes são gpt-5.6-sol-high. A adjudicação cega resolve disputas *dentro* da rubrica, e resolveu: 18 dos 19 casos em disputa no estudo inteiro foram para o meu gabarito. O que ela não pode resolver é se a rubrica corresponde ao que uma pessoa do atendimento faria. Esta é a limitação de que todas as outras derivam.

8. **Os dois braços não usam o mesmo protocolo.** O Jev responde pelo endpoint de decisões do provedor, com o campo questions nativo; o comparador responde por chat/completions, com JSON forçado, max_tokens 64 e temperature 0. O texto da rubrica é idêntico, a interface não é, e nenhuma ablação cruzada foi feita (o comparador no endpoint de decisões, ou o Jev pelo chat). Parte da diferença medida pode ser de formato, e este estudo não separa as duas coisas.

9. **A vantagem medida é sobre um corpus de armadilhas, não sobre uma amostra de trabalho.**

As 20 famílias do E11 são a instrução congelada fatiada em fenômenos: ação de terceiro, negada, condicional, já concluída, irônica, truncada. Um canal real não chega com 20 fenômenos linguísticos × 3 casos, balanceados e escritos para punir casamento lexical. Os 13,3 pontos percentuais de diferença medem **densidade de armadilha**, e o 60/60 do Jev é teto de escala, não façanha. O mesmo vale, e a seção 3.1 já registra, para a folga contra as regras congeladas: famílias inteiras foram desenhadas contra elas.

10. Um único LLM econômico foi testado como comparador. O E10 usou

meta-llama/llama-3.1-8b-instruct. Um empate com ele não é empate com a categoria, e uma vantagem sobre ele também não seria vantagem sobre a categoria. O que o E10 estabelece é que **um** modelo barato foi vencido neste corpus, e não que a categoria toda perca.

11. Nenhuma conclusão sobre os outros 14 sistemas do plano. A rodada simples offline dos 15

sistemas mostrou 5 suítes passando, 7 falhando e 3 sem como rodar. Isso é estado de repositório, não evidência de comportamento.

9. Controle financeiro e integridade do processo

O controle de gastos foi tratado como código crítico e passou por **treze rodadas de revisão independente**, todas conduzidas por modelos de outros fornecedores (gpt-6-astra via Codex e Grok 4.6 via Cursor). As quatro primeiras encontraram mais de 20 defeitos de prioridade 1, e - como o protocolo da casa prevê - as correções de cada rodada criaram defeitos novos, apanhados na rodada seguinte. Os mais graves:

- O teto era aplicado por experimento, então abrir um experimento novo abria um teto novo.
- Divergência entre o extrato do provedor e o registro local não ocupava o teto.
- Reserva e liquidação podiam usar modelos diferentes, liberando saldo inexistente.
- Respostas ausentes sumiam das métricas e inflavam a acurácia.
- O critério de significância do pré-registro original era vacuoso (intervalo de Wilson sobre uma proporção nunca cruza zero); foi substituído por bootstrap de famílias, em emenda.
- CREATE TABLE IF NOT EXISTS não adiciona coluna a tabela existente: o banco de produção

ficou sem as colunas de uma correção enquanto a suíte passava, porque a suíte usava bancos novos. Só uma verificação no estado real pegou isso.

- A migração apagava o ajuste de conciliação antes de ancorar o valor, o que devolveria ao teto dinheiro que o provedor já havia cobrado.

A sexta rodada, feita já sobre o painel pronto, encontrou o defeito mais instrutivo de todos: `authorize()` **desfazia a pausa por estouro de teto**. Todo runner chama `authorize()` no arranque e, como a função era um INSERT OR REPLACE com status fixo em `running`, bastava relançar o script para apagar a única trava que impede gasto novo depois do teto - e apagar junto as emendas registradas. A trava criada na quinta rodada não valia nada no caminho real; valia só nos testes, que a exercitavam por outro caminho.

A mesma rodada apontou que o painel havia começado a contar meia verdade: o cartão do E8 citava os dois casos em que o anotador independente apoia o Jev e omitia os dois em que ele confirma o gabarito. Corrigido no código e na seção 3.6, e é a razão de a confiança da seção 1 ter caído de 0,75 para 0,60. O texto do veredito do painel passou a ser calculado a partir dos números, em vez de prosa fixa: um texto com números escritos à mão continua afirmando o mesmo depois que os dados mudam.

A sétima rodada revisou as correções da sexta e encontrou o que o protocolo desta casa sempre encontra: um defeito novo, criado pela própria correção. O `authorize()` corrigido deixou de apagar a pausa, mas continuava reescrevendo o teto do experimento - e como todo runner o chama com US\$ 5,00 no arranque, **uma emenda**

que baixasse o teto para US\$ 1,00 seria desfeita pelo próximo `python -m executor.run_e*`, sem registro.

Agora `authorize` só reduz; ampliar exige `ampliar_teto_do_experimento(motivo, evidencia)` e nunca passa do teto da carteira.

A mesma rodada cobrou a adjudicação dos 9 casos em disputa do E8, e a cobrança estava certa: dois anotadores que discordam não produzem verdade. A adjudicação foi feita (seção 3.6.1) e **mudou o resultado contra o modelo**, não a favor.

Conciliação de encerramento contra o extrato do provedor: o ledger registra US\$ 0,017182296 para o OpenRouter; o provedor cobrou US\$ 0,017095092. O ledger está **acima** do extrato em US\$ 0,000087, e a diferença é explicada: são as chamadas que voltaram HTTP 400 na fase de sondagem do contrato, provisionadas aqui e não cobradas lá. Nenhum excedente a absorver, nenhum gasto sem identidade de provedor. Somando o TypeSafe direto (US\$ 0,000992166), o total comprometido é US\$ 0,022618774.

A oitava rodada não encontrou defeito financeiro novo - o teto passou a ser, nas palavras do revisor, "o pedaço mais honesto do repositório". Encontrou coisa pior no painel: depois de adjudicar o gabarito, **o placar passou a se contradizer**. O veredito citava 87,5% em 40 casos da confirmação e o cartão ao lado citava 80% em 80 casos da união; um cartão do E8 dizia 3 erros e o outro dizia 4; e as pendências continuavam pedindo a adjudicação que o painel acabara de anunciar. Três gabaritos circulavam ao mesmo tempo e cada parte usava o que tinha à mão.

A correção não foi cosmética: `executor/gabarito.py` passou a definir **um** gabarito oficial (o do autor, com os casos em disputa substituídos pela adjudicação), o E9 passou a consumi-lo, cada cartão declara qual gabarito está por trás do seu número, e `politica_de_referencia()` devolve uma leitura só - sem cair silenciosamente na união quando a partição falta. O teste `test_coerencia_placar.py` roda o painel contra os relatórios reais e falha se veredito e cartão divergirem.

A nona rodada não achou defeito financeiro - e achou, de novo, o painel falando duas línguas. O cartão do E7 estampava 97,5% (gabarito do autor) e narrava, na linha de baixo, que no gabarito oficial não havia erro nenhum; a nota de confiança justificava o corte de 0,90 com 80 casos da união enquanto o veredito, ao lado, falava de 40 casos da confirmação. A correção da oitava tinha unificado o par que a revisão apontou com o dedo, e só ele.

Agora `executor/gabarito.py` recalcula cada conjunto **sob os dois gabaritos, na mesma conta**, e o cartão mostra a **faixa** - 97,5% a 100,0% no E7 - em vez do melhor dos dois. Com um número só, o olho pega o mais alto e a ressalva vira letra miúda. A nota de confiança passou a citar a mesma base da política que recomenda, e o título do veredito usa a mesma função de política do resto do painel.

A décima rodada não achou defeito financeiro e achou uma promessa impossível no painel: o veredito oferecia a **cobertura da partição de confirmação (87,5%) com o custo da união (US\$ 0,080)**. Custo por decisão depende da fração que vai para revisão humana, que é justamente o que a cobertura mede; as duas coisas têm de sair da mesma partição. Ou 87,5% a US\$ 0,050, ou 80% a US\$ 0,080. O meio-termo era o número preferido de cada coluna.

Corrigido: `politica_de_referencia()` passou a devolver também a política de revisar tudo da mesma partição, o veredito usa as duas, e um teste quebra se o custo da união aparecer ao lado da cobertura da confirmação. Na mesma rodada, o cartão do E8 deixou de estampar 96,2% - o mais alto dos três gabaritos - e passou a mostrar a faixa 88,8% a 96,2%, como o E7 já fazia.

A décima primeira e a décima segunda rodadas não acharam defeito financeiro; acharam o painel mostrando **dois gabaritos onde existem três**. O gabarito do anotador independente é o mais severo - no piloto dá 87,5% contra 92,5% do autor, e na confirmação 90,0% contra 97,5% - e ficava de fora dos cartões que se lê primeiro. O

rótulo que deveria denunciar isso perguntava a coisa errada: se a adjudicação mudou algum caso, e não se os anotadores discordaram. Com essa pergunta, o piloto aparecia como unânime tendo quatro casos em disputa dentro dele.

A décima terceira rodada trocou de método: em vez de reler o código, **mutou os dados** e perguntou quais cartões se mexiam. Zerando as nove divergências do anotador independente dentro de `runs/e8-anotador/relatorio.json`, os cartões do E1 e do E7 acompanharam e o do E8 ficou parado. Ele não recalculava nada - lia dois agregados gravados dentro do próprio relatório no momento em que aquele experimento rodou. Era o defeito da nona rodada, número velho em caixa nova, sobrevivendo justamente no cartão que fala de gabarito. A correção criou `gabarito.desempenho_do_estudo()`, que soma E1 e E7 sob os três gabaritos na hora da leitura, e o teste de mutação virou teste permanente.

A auditoria de mutação foi então aplicada a todos os relatórios, e achou um **segundo** cartão cego: o E3 lia o bloco `jev` gravado no alto de `runs/e3-evidencia/relatorio.json` em vez de contar os casos. Os dois números batem hoje - 23 acertos em 24 - e é justamente por isso que nenhum teste de coerência podia pegá-lo: um número congelado parece correto enquanto ninguém mexe nos dados. Trocados cinco acertos por erros, o cartão continuava estampando 95,8%. Hoje ele recalcula e a auditoria de mutação virou teste permanente sobre todos os relatórios que têm lista de casos.

A mesma rodada achou um defeito que nenhum teste do painel podia achar, porque não estava no painel: `output/pdf/PLANO-CIENTIFICO-JEV-HELENA.pdf` e `output/pdf/RELATORIO-FINAL-JEV.pdf` **eram o mesmo arquivo**, byte a byte, e já tinham sido versionados assim. O gerador do relatório chamava a função que monta o PDF do plano e copiava o resultado; aquela função gravava sempre no caminho do plano e montava sempre a capa do plano. Cada build do relatório destruía o plano, e o relatório que foi entregue abria anunciando `"ensaios dos sistemas ainda pendentes"` - depois de todos os ensaios terminados. Capa e destino passaram a ser do chamador, o relatório ganhou capa própria com números vindos do placar, e dois testes novos exigem que cada PDF abra no documento que o nome dele promete.

A mesma décima terceira rodada cobrou quatro coisas que eu podia verificar e uma que eu podia executar. As quatro: o pré-registro do E1 mandava reportar erro grave separado da acurácia média, e isso nunca tinha sido feito (seção 3.7); o `runs/ledger.sqlite3` é ignorado pelo Git, e sem ele o custo publicado era uma citação que ninguém de fora podia conferir (agora `runs/extrato-ledger.json` vai versionado); o `.gitignore` tinha `runs/` puro, e como o Git não desce em diretório excluído **nenhuma** das exceções abaixo dele valia; e o README dizia "nove rodadas" enquanto este documento dizia treze.

A quinta foi a que importou. O revisor apontou que o único comparador do estudo era uma regra congelada que eu mesma escrevi, e que a pergunta P1 do plano seguia sem metade da resposta. Executei o E10 (seção 3.8), com regra de decisão congelada antes da primeira chamada. O resultado contrariou a recomendação que este documento vinha fazendo desde a primeira versão, e a recomendação mudou. Custou US\$ 0,000358 e treze rodadas de revisão não o teriam encontrado, porque nenhuma delas estava olhando para fora do que já havia sido medido.

O E10 e o E10b abriram uma divisão que nenhum dos dois podia fechar, e o E11 foi escrito para fechá-la: corpus novo, 20 famílias declaradas antes do primeiro caso, regra de decisão congelada antes de existir dado. Ele fechou, mas não onde eu esperava. A vantagem do Jev sobre o comparador barato é nítida sob o meu gabarito e some sob o do anotador independente - mesma execução, mesmas respostas, mesmos 60 casos.

Três defeitos apareceram no caminho e estão corrigidos: a primeira execução do E11 perdeu 120 chamadas pagas porque nada era persistido; `titulo_do_veredito` tinha virado impura e passou a responder pelo repositório em vez de responder pelos dados que recebia; e o run de tentativas órfãs se substituiu a cada publicação, apagando as próprias órfãs e desfazendo em silêncio a reconciliação de custo que a oitava rodada tinha

estabelecido.

A décima quarta rodada foi a mais útil de todas, e foi a que me corrigiu contra mim mesma. Ela mostrou que eu havia enterrado um resultado pré-registrado usando como ouro um modelo de 7B cujo modo de errar é justamente o que o sistema avaliado supera; que o procedimento para resolver isso já existia no próprio estudo, o terceiro juiz cego do E8b, e que o E11 tinha parado antes dele. Rodei, sob emenda com a regra escrita antes, e o juiz confirmou meu gabarito em 10 de 10. A recomendação mudou pela quinta vez.

A mesma rodada achou três números velhos que conviviam com os novos no texto canônico - 625 chamadas e US\$ 0,018174462 na seção 7, na seção 9 e no README - e um kappa publicado que era anterior à ampliação do E8. O teste que existia exigia que o número certo aparecesse; não exigia que o errado sumisse. Agora exige.

A décima quinta rodada não encontrou defeito financeiro, e encontrou o documento ainda argumentando a recomendação anterior enquanto a seção 1 publicava a nova: a 3.10 se intitulava **"por que ele não desempatou"** e fechava dizendo que o relatório **"não fecha a favor de ninguém"**. Achou também uma afirmação que eu havia acabado de escrever e que era falsa - a de que o erro grave seria a métrica que não depende do gabarito. O único falso-cancelar do comparador está entre os 10 casos em disputa, e sob o gabarito do anotador independente ele desaparece. Reconto agora sob os três, e o que sobra é mais modesto.

Estado final: **945 tentativas, nenhuma reserva pendente sem liquidação, US\$ 0,022618774 de US\$ 5,00, 151 testes automatizados passando.** A chave da API nunca foi versionada, impressa em log ou copiada para documentação.

10. Próximo movimento

1. **Repetir o E10 em amostra maior**, com pelo menos 30 famílias, e com dois ou três LLMs

econômicos em vez de um - critério: o IC95 da diferença pareada separar de zero, ou não separar com poder suficiente para que "não separa" signifique alguma coisa. É o movimento mais barato da lista (as 40 chamadas custaram US\$ 0,000358) e o que mais muda a decisão: se o empate se confirmar, a discussão deixa de ser "qual modelo" e passa a ser "qual o mais barato que passa".

2. **Coletar 200 mensagens reais de um canal de atendimento**, com a distribuição de classes que o canal tem - responsável: Igor; critério: corpus anonimizado disponível em `data/corpus/`.

3. **Anotar com dois humanos independentes** e medir kappa entre eles antes de olhar o modelo - critério: kappa humano-humano $\geq 0,80$; abaixo disso, o problema é a definição das classes, não o modelo.

4. **Rodar a política do corte 0,90 em sombra** sobre esse corpus real, sem efeito em produção, medindo cobertura e erro entre aceitos - critério: erro entre aceitos $\leq 1\%$ com cobertura $\geq 70\%$.

5. **Cronometrar o fluxo humano** durante a sombra, para fechar a pergunta P5 com dado medido em vez de parâmetro declarado.

6. **Só então** decidir se a política sobe para produção, e com qual corte.

Os itens 2 e 3 dependem de gente, não de orçamento; o item 1 depende só de orçamento, e de muito pouco. Restam US\$ 4,98 do teto autorizado, o que cobre com folga toda a fase de sombra.

O estudo que eu queria ter feito é o que começa no item 1. O que está aqui é o que dá para saber sem dados reais - e o principal valor dele é ter descoberto, antes de gastar, exatamente onde o modelo quebra: no mesmo caso, perguntado duas vezes.

- **Helena.** Café preto, sem açúcar.