

Testar todos. Medir o que importa.

Um plano científico para avaliar os 15 sistemas Jev e decidir onde há benefício real no trabalho.

15 sistemas	96 decisões	US\$ 0
Rodadas simples e profundas	Histórico recalculado do PDF	Inferência nova nesta etapa

Decisão proposta

Reaproveitar a evidência do Hermes, criar casos novos bem rotulados e comparar qualidade, custo e tempo no fluxo completo.

A interface e os documentos estão prontos. Os ensaios dos sistemas, o executor e o bloqueio financeiro continuam como próximos passos do plano.

18 de setembro de 2026

Cenário financeiro conservador: US\$ 1,997062454 disponíveis dentro do teto total de US\$ 5, incluindo o histórico reportado.

Mapa de leitura

1. Recomendação	3
2. Achado principal	3
3. Evidência	4
4. Mecanismo: por que funciona	7
5. Contra-hipóteses testadas	7
6. Calibração	8
7. Custo e operação	8
8. Limites - o que este estudo não autoriza afirmar	9
9. Controle financeiro e integridade do processo	9
10. Próximo movimento	11

Comece pelas seções 1, 3, 7 e 8. A metodologia e o contrato de dados estão nas seções 4 a 6 e 9. As fichas dos 15 sistemas encerram o documento.

Autoria: Dra. Helena Strategos, Cientista-Chefe de Inteligência da INTEIA **Execução:** 18-19 de setembro de 2026 **Sistema avaliado:** Jev 1.13 (typesafe/jev-1.13 via OpenRouter e jev-1.13.0 direto) **Custo total:** US\$ 0,018174462 em 625 chamadas, de um teto autorizado de US\$ 5,00 **Código, dados e registros:** este repositório, com pré-registros em `planning/` e relatórios brutos em `runs/`

1. Recomendação

Use o Jev como classificador consultivo com corte de confiança em 0,90 e revisão humana do que ficar abaixo. Não o use como decisor automático sem revisão.

A política concreta que os dados sustentam: aceitar automaticamente as decisões com confiança $\geq 0,90$ e encaminhar o restante para uma pessoa. Na partição de confirmação - os 40 casos que não guiaram o desenho, que é a leitura que vale para decidir - essa política aceita **87,5%** sem nenhum erro observado entre os aceitos; na união dos 80 casos, aceita 80%, também sem erro observado. Os quatro erros do modelo têm confiança abaixo de 0,90.

A base é pequena e o número precisa ser lido assim: são 4 erros em 80 casos. "Nenhum erro entre os aceitos" descreve o que foi observado, não uma garantia; a seção 6 traz o limite superior que sobra depois de respeitar o agrupamento por família. Sob os parâmetros da seção 7 - declarados, nunca cronometrados - a política leva o custo por decisão de US\$ 0,400 para US\$ 0,080.

O que impede a recomendação de ir além disso: o modelo não é determinístico. O mesmo caso, sozinho e repetido cinco vezes, pode mudar de resposta. Um sistema que decide sozinho precisa responder igual à mesma pergunta, e este não responde.

Acurácia do modelo nestes 80 casos: entre 0,8875 e 0,9750, conforme o gabarito adotado. Sob o gabarito adjudicado por três juízes - o mais defensável - são **0,9625**. Reportar só o número mais alto seria escolher o gabarito depois de ver o resultado.

Confiança: 0,60. Rebaixada de 0,75 depois da sexta rodada de revisão independente, que mostrou que o painel havia começado a apresentar duas lacunas conhecidas como se estivessem fechadas. Alta para a comparação contra os comparadores congelados - é pareada, pré-registrada e replicou fora do corpus piloto. Baixa para qualquer afirmação operacional: 80 casos construídos por mim, gabarito de um anotador humano (também eu), e um corte apoiado em 4 erros.

2. Achado principal

A confiança que o modelo reporta é informativa, e essa é a descoberta com mais valor operacional do estudo.

Não era óbvio. `confidence` é um número que o modelo emite sobre a própria resposta; nada garante que corresponda a probabilidade de acerto. Mas nos dois corpora, todos os erros ficaram concentrados abaixo de 0,90, e nenhum caso aceito acima desse corte estava errado. É isso que torna viável uma política de triagem com revisão seletiva, em vez de revisão total.

A ressalva é grande e vai na seção 8: zero erro em 64 casos aceitos não é taxa de erro zero. Respeitando o agrupamento por família, o limite superior do erro ainda chega a 25,9%.

3. Evidência

3.1 Comparação contra comparadores congelados

Os três primeiros resultados abaixo usam o **gabarito do autor**, como pré-registrado. O gabarito oficial do estudo, depois da adjudicação da seção 3.6.1, está na seção 3.6 e move os números para cima; mantenho os dois porque trocar de gabarito depois de ver o resultado é exatamente o que um pré-registro existe para impedir.

Experimento	Jev	Comparador	Diferença pareada (IC95, bootstrap de famílias)
E1 triagem, piloto (40 casos, 10 famílias)	0,925	regra de palavras-chave 0,600	+0,325 [0,150; 0,500]
E3 suporte por evidência (24 casos, 6 famílias)	0,958	regra ingênua 0,625	+0,333 [0,250; 0,417]
E7 triagem, confirmação (40 casos, 10 famílias)	0,975	mesma regra congelada 0,325	+0,650 [0,525; 0,775]

O E7 é o experimento que mais importa: 40 casos escritos **depois** de o sistema estar congelado, pré-registrados, projetados para armadilhas que o piloto não cobria. A vantagem não encolheu fora do piloto - que era o risco real de um estudo desenhado pelo próprio avaliador.

Ressalva registrada em emenda ao pré-registro, antes de aparecer em qualquer resumo: a vantagem cresceu porque o comparador piorou, não porque o Jev melhorou. O Jev foi de 0,925 para 0,975 (dois casos); a regra caiu de 0,600 para 0,325, porque escrevi famílias inteiras contra casamento de palavras-chave. A comparação honesta entre corpora é a do Jev consigo mesmo.

3.2 Ressalvas e exceções (E4)

Oito consultas, cinco candidatos cada, com ressalvas críticas plantadas. Perder uma ressalva no topo significa que a exceção não chega a quem decide.

Ordenação	Ressalvas no topo-3	nDCG@5
Jev	8/8	0,9958
BM25	5/8	0,9205
Ordem de chegada	4/8	0,7359

O corpus foi embaralhado com semente fixa antes da execução, porque na primeira versão ele estava em ordem decrescente de relevância e a "ordem de chegada" ganhava de graça.

3.3 Formato, lote e posição (E2, E2b)

Desenho fatorial 2×2×2 (lote × ordem das opções × distração), 8 condições sobre os mesmos 40 casos, ordem de execução embaralhada. Acurácia entre 0,925 e 0,950; **McNemar p = 1,000 em todos os contrastes** - nenhuma condição se separa das outras. O lote de 8 reduz o custo por decisão em 32% a 43%.

O E2 sugeriu que as posições 4 e 8 do lote eram piores. O E2b desconfundiu: com a ordem dos casos fixa, posição e caso eram a mesma variável. Embaralhando em 5 permutações (200 observações), o efeito de posição desaparece: **permutação p = 0,403**. O que sobra é outro achado, que virou o E6.

3.4 Estabilidade (E2b, E6)

- **No lote:** 3 casos em 40 mudam de resposta conforme os vizinhos do lote.
- **Isolado:** com uma pergunta por chamada, repetida 5 vezes, **1 caso em 40** ainda muda de resposta entre repetições idênticas - e é um dos três.

Conclusão: parte da instabilidade é do próprio modelo, não do agrupamento. Voto majoritário de cinco chamadas leva a acurácia de 0,925 a 0,950: **um caso a mais, a cinco vezes o custo**.

3.5 Transporte (E5)

OpenRouter contra o endpoint TypeSafe direto, mesmos 40 casos, chamadas intercaladas para que uma deriva do serviço não caísse sobre um só braço.

	Concordância	Acurácia	Latência p50	Custo por decisão
OpenRouter	\-	0,925	396 ms	22.167 nUSD
TypeSafe direto	40/40 (100%)	0,925	755 ms	24.804 nUSD

Decisão idêntica em todos os casos. O direto é ~2× mais lento e ~12% mais caro, porque cobra tokens de saída que o OpenRouter não cobra. **Não há motivo técnico para trocar de transporte.**

3.6 Qualidade do gabarito (E8)

A limitação mais séria de todo o estudo era ter um anotador só. Um anotador independente e cego (qwen2.5-7b local, custo zero, outro fornecedor e outra arquitetura) classificou os 80 casos vendo apenas as instruções e os critérios - sem o gabarito e sem a resposta do Jev.

- **Kappa de Cohen: 0,859.** Concordância bruta 88,8%, 9 divergências em 80.
- Dos **4 erros do Jev** sob o meu gabarito, o anotador independente ****confirma o meu gabarito** em 2 (**tri-f06-02, tri-f09-04 - erros claros do modelo**) e fica do lado do Jev em 2** (**tri-f02-04, cnf-g05-02**). Nas outras 7 divergências foi o anotador que caiu na armadilha, com o Jev do lado do gabarito.
- **Sob o gabarito do outro anotador, o Jev faz 0,8875, não 0,95.** A acurácia depende de qual gabarito se adota, e é exatamente essa fragilidade que o experimento veio expor.

3.6.1 Adjudicação cega dos 9 casos em disputa

A sétima rodada de revisão apontou, com razão, que sem adjudicação o E8 não fechava nada: dois anotadores que discordam não produzem verdade, produzem uma disputa. Os 9 casos foram então submetidos a um **terceiro juiz** (gpt-5.6-sol-high, outro fornecedor ainda), que recebeu só a mensagem e as duas leituras **em ordem sorteada**, sem saber qual veio de quem.

	Resultado
Casos em que o terceiro juiz confirma o gabarito do autor	8 de 9
Casos em que confirma o anotador local	1 de 9 (cnf-g05-02)
Casos em que propôs uma terceira leitura	0

Este resultado corrige a leitura anterior deste relatório, e corrige-a contra o modelo. Eu havia registrado que em 2 dos 4 erros "o suspeito é o meu gabarito". A adjudicação diz outra coisa: em tri-f02-04 o terceiro juiz ficou comigo, e o Jev errou mesmo. Só cnf-g05-02 - o caso que eu já havia declarado contestável antes de ver qualquer um destes resultados - mudou de lado, e mudou contra mim.

Sob o gabarito adjudicado, o Jev faz 0,9625 (77/80), com três erros: tri-f02-04, tri-f06-02 e tri-f09-04 - **todos do corpus piloto**. No conjunto de confirmação, que é a partição de teste, o gabarito adjudicado deixa o modelo **sem erro nenhum**, porque o único erro que havia lá (cnf-g05-02) foi justamente o caso que mudou de lado. Isso não deve ser lido como "40/40 no teste": é um resultado de 40 casos em que o único erro virou disputa e a disputa foi decidida por um terceiro modelo. O número que eu levaria a uma reunião é o de 80 casos, 0,9625. A faixa honesta de acurácia do modelo nestes 80 casos é **0,8875 a 0,9750**, conforme o gabarito adotado; o adjudicado, que é o mais defensável dos três, fica em 0,9625.

O limite desta adjudicação, dito antes que alguém o use contra o resultado: o terceiro juiz é um modelo de linguagem grande, como o Jev. Modelos grandes treinados em dados parecidos tendem a compartilhar a mesma convenção sobre o que é "a ação pedida" - a concordância de 8 em 9 pode estar medindo essa convenção compartilhada, e não a verdade do domínio. O desenho controla o que dá para controlar (ordem sorteada, juiz cego à autoria, nenhum acesso ao repositório), mas não controla isso. Uma adjudicação com três pessoas do atendimento real poderia chegar a outro lugar, e continua sendo o item 2 da seção 10.

Ressalva que não pode ser omitida: um modelo de 7B não é anotador humano, e o E8 **não é a adjudicação de gabarito** que o estudo precisa. Ele recebeu a minha rubrica e reproduziu a minha rubrica; kappa alto aqui mede reprodutibilidade, não validade do constructo. O padrão das divergências mostra viés claro - em 6 das 9 ele viu ação onde eu li pedido de informação, que é precisamente a armadilha que as instruções mandam evitar. E os 71 casos de "consenso" são os casos em que os dois concordam, ou seja, os fáceis: a acurácia de 0,9718 ali **não é uma medida melhor, é uma medida sobre um subconjunto mais fácil**, e não corrige nada. Os 9 casos em disputa **foram adjudicados** (seção 3.6.1), mas por um terceiro modelo, não por uma pessoa. **O anotador humano continua pendente**, e o que a adjudicação mostra é que a rubrica é reproduzível entre juízes independentes - não que ela seja a definição certa do problema.

4. Mecanismo: por que funciona

A vantagem sobre as regras não vem de vocabulário maior. Vem de resolver três coisas que o casamento de palavras não resolve, e que as famílias do corpus isolam uma a uma:

1. **Quem realiza a ação.** "Minha esposa cancelou o pedido dela; o meu não chegou" contém "cancelou" e não é um pedido de cancelamento.
2. **O estatuto da ação.** Ação negada ("não quero cancelar nada"), condicional ("se não chegar até sexta, vou querer cancelar") ou já concluída ("já cancelei pelo site") não é a ação pedida.
3. **A palavra contra o pedido.** "Solicito o estorno do aparelho com defeito: mandem um novo" usa o léxico financeiro para pedir uma troca.

A regra congelada acerta a família 1 do piloto quase inteira e desaba nas famílias G06 e G07 do conjunto de confirmação. É essa diferença que o número +0,650 do E7 está medindo.

5. Contra-hipóteses testadas

Contra-hipótese 1: o corpus foi desenhado para o sistema ganhar

Argumento: escrevi os casos conhecendo o Jev e a regra. Um corpus assim mede o autor. **Teste executado:** E7, com 40 casos novos, pré-registrados, com o sistema já congelado. **Resultado:** a vantagem não encolheu. Mas registrei que ela cresceu por piora do comparador, não por melhora do Jev. **Parcialmente refutada, com ressalva permanente.**

Contra-hipótese 2: o gabarito está errado onde o Jev "erra"

Argumento: um anotador só define a verdade que ele mesmo vai avaliar. **Teste executado:** E8, anotador independente e cego. **Teste executado:** E8 mais a adjudicação cega dos 9 casos em disputa por um terceiro juiz. **Resultado: refutada, e refutada contra o modelo.** O terceiro juiz confirmou o meu gabarito em 8 dos 9 casos. Sob o gabarito adjudicado o Jev faz 0,9625, com três erros reais - não dois. A hipótese de que "o gabarito é que está errado onde o modelo erra" só se sustentou em um caso, o mesmo que eu já havia declarado contestável antes de ter qualquer resultado.

Contra-hipótese 3: o ganho é do formato, não do modelo

Argumento: talvez lote, ordem das opções ou distração expliquem os resultados. **Teste executado:** E2 fatorial completo, mais E2b para desconfundir posição. **Resultado:** nenhuma condição se separa (McNemar $p = 1,000$). **Refutada.**

Contra-hipótese 4: o resultado depende do provedor

Teste executado: E5, dois transportes intercalados. **Resultado:** 40/40 de concordância. **Refutada.**

Contra-hipótese 5: a acurácia cai numa distribuição de classes realista

Argumento: os corpora são quase balanceados; um canal real não é. **Teste executado:** E9, reponderação da matriz de confusão sob quatro distribuições, no gabarito oficial. **Resultado:** acurácia esperada entre 0,9502 e 0,9724 - varia pouco, porque nenhuma classe é fraca. **Refutada dentro da suposição de que a dificuldade dentro de cada classe é a mesma do corpus**, que é uma suposição grande e não testada.

6. Calibração

Medida na partição de teste (conjunto de confirmação), que é a leitura honesta:

Corte	Aceitos	Cobertura	Erros observados	Limite superior de erro (por família)
0,90	35/40	87,5%	0	-
0,95	34/40	85,0%	0	25,9%
0,99	28/40	70,0%	0	25,9%

Zero erro observado não é taxa de erro zero. Os aceitos vêm de um número pequeno de famílias, e famílias são a unidade de dependência. O limite por caso (Clopper-Pearson sobre 34 ensaios) daria um número muito menor, e seria enganoso: trataria casos da mesma família como observações independentes, o que eles não são.

7. Custo e operação

Medido: 625 chamadas, US\$ 0,018174462 no total. Custo por decisão individual ~US\$ 0,000022. Latência mediana 396 ms no OpenRouter.

Declarado, não medido: 2 minutos por revisão humana, US\$ 12,00 por hora. Nenhum cronômetro foi usado; trocar esses parâmetros muda toda a tabela abaixo.

A tabela abaixo usa a **união dos 80 casos**. A partição de confirmação sozinha dá cobertura maior no mesmo corte (87,5% contra 80,0%), então a linha do corte 0,90 aqui é a leitura conservadora, não a otimista.

Política	Cobertura automática	Erros entre aceitos	Custo por decisão	Economia
Revisar tudo	0%	-	US\$ 0,400	-
Corte 0,99	66,3%	0	US\$ 0,135	66,2%
Corte 0,95	77,5%	0	US\$ 0,090	77,5%
Corte 0,90	80,0%	0	US\$ 0,080	80,0%
Aceitar tudo	100%	3	US\$ 0,000022	100%

A linha "aceitar tudo" é o que a automação total custaria e o que ela erraria. A diferença entre ela e o corte 0,90 é o preço de não errar: US\$ 0,08 por decisão.

8. Limites - o que este estudo não autoriza afirmar

1. **Não é um teste em dados reais.** Os 80 casos de triagem e os 24 de evidência foram construídos por mim. Nenhum veio de um canal de atendimento em produção.
2. **Um anotador humano.** O E8 mitigou com um juiz independente, mas um modelo de 7B não substitui uma segunda pessoa. Dois dos quatro "erros" do Jev podem ser erro meu.
3. **Amostra pequena.** 10 famílias por corpus. O bootstrap respeita o agrupamento, e por isso os intervalos são largos - o que é honesto, não um defeito.
4. **O modelo não é determinístico.** Confirmado com o caso isolado e repetido.
5. **Tempo humano não foi cronometrado.** A tabela da seção 7 é uma conta de sensibilidade, não uma medição de fluxo real. Isso era a pergunta P5 do plano e continua aberta.
6. **confidence não foi validado como probabilidade.** Foi validado como *ordenador*: separa bem o que está certo do que está errado nestes 80 casos. Não é a mesma coisa.
7. **Nenhuma conclusão sobre os outros 14 sistemas do plano.** A rodada simples offline dos 15 sistemas mostrou 5 suítes passando, 7 falhando e 3 sem como rodar. Isso é estado de repositório, não evidência de comportamento.

9. Controle financeiro e integridade do processo

O controle de gastos foi tratado como código crítico e passou por **oito rodadas de revisão independente**, todas conduzidas por modelos de outros fornecedores (gpt-6-astra via Codex e Grok 4.6 via Cursor). As quatro primeiras encontraram mais de 20 defeitos de prioridade 1, e - como o protocolo da casa prevê - as correções de cada rodada criaram defeitos novos, apanhados na rodada seguinte. Os mais graves:

- O teto era aplicado por experimento, então abrir um experimento novo abria um teto novo.
- Divergência entre o extrato do provedor e o registro local não ocupava o teto.
- Reserva e liquidação podiam usar modelos diferentes, liberando saldo inexistente.
- Respostas ausentes sumiam das métricas e inflavam a acurácia.
- O critério de significância do pré-registro original era vacuoso (intervalo de Wilson sobre uma proporção nunca cruza zero); foi substituído por bootstrap de famílias, em emenda.
- `CREATE TABLE IF NOT EXISTS` não adiciona coluna a tabela existente: o banco de produção

ficou sem as colunas de uma correção enquanto a suíte passava, porque a suíte usava bancos novos. Só uma verificação no estado real pegou isso.

- A migração apagava o ajuste de conciliação antes de ancorar o valor, o que devolveria ao teto dinheiro que o provedor já havia cobrado.

A sexta rodada, feita já sobre o painel pronto, encontrou o defeito mais instrutivo de todos: `authorize()` **desfazia a pausa por estouro de teto**. Todo runner chama `authorize()` no arranque e, como a função era um `INSERT OR REPLACE` com status fixo em `running`, bastava relançar o script para apagar a única trava que impede gasto novo depois do teto - e apagar junto as emendas registradas. A trava criada na quinta rodada não valia nada no caminho real; valia só nos testes, que a exercitavam por outro caminho.

A mesma rodada apontou que o painel havia começado a contar meia verdade: o cartão do E8 citava os dois casos em que o anotador independente apoia o Jev e omitia os dois em que ele confirma o gabarito. Corrigido no código e na seção 3.6, e é a razão de a confiança da seção 1 ter caído de 0,75 para 0,60. O texto do veredito do painel passou a ser calculado a partir dos números, em vez de prosa fixa: um texto com números escritos à mão continua afirmando o mesmo depois que os dados mudam.

A sétima rodada revisou as correções da sexta e encontrou o que o protocolo desta casa sempre encontra: um defeito novo, criado pela própria correção. O `authorize()` corrigido deixou de apagar a pausa, mas continuava reescrevendo o teto do experimento - e como todo runner o chama com US\$ 5,00 no arranque, **uma emenda que baixasse o teto para US\$ 1,00 seria desfeita pelo próximo** `python -m executor.run_e*`, sem registro. Agora `authorize` só reduz; ampliar exige `ampliar_teto_do_experimento(motivo, evidencia)` e nunca passa do teto da carteira.

A mesma rodada cobrou a adjudicação dos 9 casos em disputa do E8, e a cobrança estava certa: dois anotadores que discordam não produzem verdade. A adjudicação foi feita (seção 3.6.1) e **mudou o resultado contra o modelo**, não a favor.

Conciliação de encerramento contra o extrato do provedor: o ledger registra US\$ 0,017182296 para o OpenRouter; o provedor cobrou US\$ 0,017095092. O ledger está **acima** do extrato em US\$ 0,000087, e a diferença é explicada: são as chamadas que voltaram HTTP 400 na fase de sondagem do contrato, provisionadas aqui e não cobradas lá. Nenhum excedente a absorver, nenhum gasto sem identidade de provedor. Somando o TypeSafe direto (US\$ 0,000992166), o total comprometido é US\$ 0,018174462.

A oitava rodada não encontrou defeito financeiro novo - o teto passou a ser, nas palavras do revisor, "o pedaço mais honesto do repositório". Encontrou coisa pior no painel: depois de adjudicar o gabarito, **o placar passou a se contradizer**. O veredito citava 87,5% em 40 casos da confirmação e o cartão ao lado citava 80% em 80 casos da união; um cartão do E8 dizia 3 erros e o outro dizia 4; e as pendências continuavam pedindo a adjudicação que o painel acabara de anunciar. Três gabaritos circulavam ao mesmo tempo e cada parte usava o que tinha à mão.

A correção não foi cosmética: `executor/gabarito.py` passou a definir **um** gabarito oficial (o do autor, com os casos em disputa substituídos pela adjudicação), o E9 passou a consumi-lo, cada cartão declara qual gabarito está por trás do seu número, e `politica_de_referencia()` devolve uma leitura só - sem cair silenciosamente na união quando a partição falta. O teste `test_coerencia_placar.py` roda o painel contra os relatórios reais e falha se veredito e cartão divergirem.

Estado final: **625 tentativas, nenhuma reserva pendente sem liquidação, US\$ 0,018174462 de US\$ 5,00, 117 testes automatizados passando**. A chave da API nunca foi versionada, impressa em log ou copiada para documentação.

10. Próximo movimento

1. **Coletar 200 mensagens reais de um canal de atendimento**, com a distribuição de classes que o canal tem - responsável: Igor; critério: corpus anonimizado disponível em `data/corpus/`.
2. **Anotar com dois humanos independentes** e medir kappa entre eles antes de olhar o modelo - critério: kappa humano-humano $\geq 0,80$; abaixo disso, o problema é a definição das classes, não o modelo.
3. **Rodar a política do corte 0,90 em sombra** sobre esse corpus real, sem efeito em produção, medindo cobertura e erro entre aceitos - critério: erro entre aceitos $\leq 1\%$ com cobertura $\geq 70\%$.
4. **Cronometrar o fluxo humano** durante a sombra, para fechar a pergunta P5 com dado medido em vez de parâmetro declarado.
5. **Só então** decidir se a política sobe para produção, e com qual corte.

Os itens 1 e 2 dependem de gente, não de orçamento. Restam US\$ 4,98 do teto autorizado, o que cobre com folga toda a fase de sombra.

O estudo que eu queria ter feito é o que começa no item 1. O que está aqui é o que dá para saber sem dados reais - e o principal valor dele é ter descoberto, antes de gastar, exatamente onde o modelo quebra: no mesmo caso, perguntado duas vezes.

- **Helena.** Café preto, sem açúcar.